Ceph
THE FUTURE OF STORAGE

ghostwydwu （武勇栋）



Ceph

1. 什么是ceph

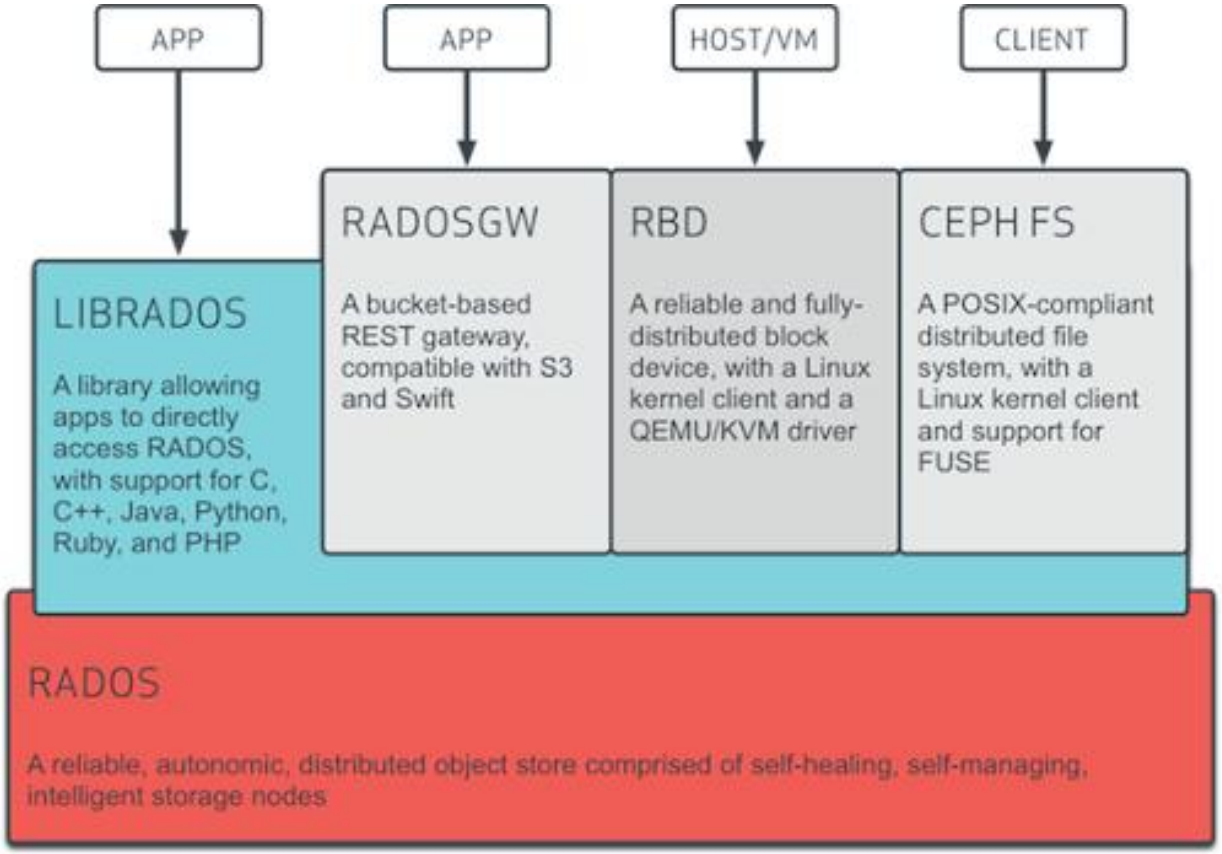
Ceph is a unified, distributed storage system designed for excellent performance, reliability and scalability

2.Ceph的特征

- 统一的存储系统，支持对象存储、块存储和文件系统存储三种接口
- 高扩展性：使用普通x86服务器，支持10~1000台服务器，支持TB到PB级的扩展
- 高可靠性：没有单点故障，多数据副本，自动管理，自动修复。
- 高性能：数据分布均衡，并行化度高。对于objects storage和block storage,不需要元数据服务器。

腾讯网 QQ.com

Ceph存储结构



腾讯网 QQ.com

Ceph角色分类

- OSD（Object Storage Device）：提供存储资源，存储数据，类似TSSD中cell的角色。OSD会定期和其它OSD做心跳，探测有问题的OSD并向monitor上报

- Monitor：维护整个Ceph集群的全局状态，接受从OSD上报的信息并更新OSD状态。

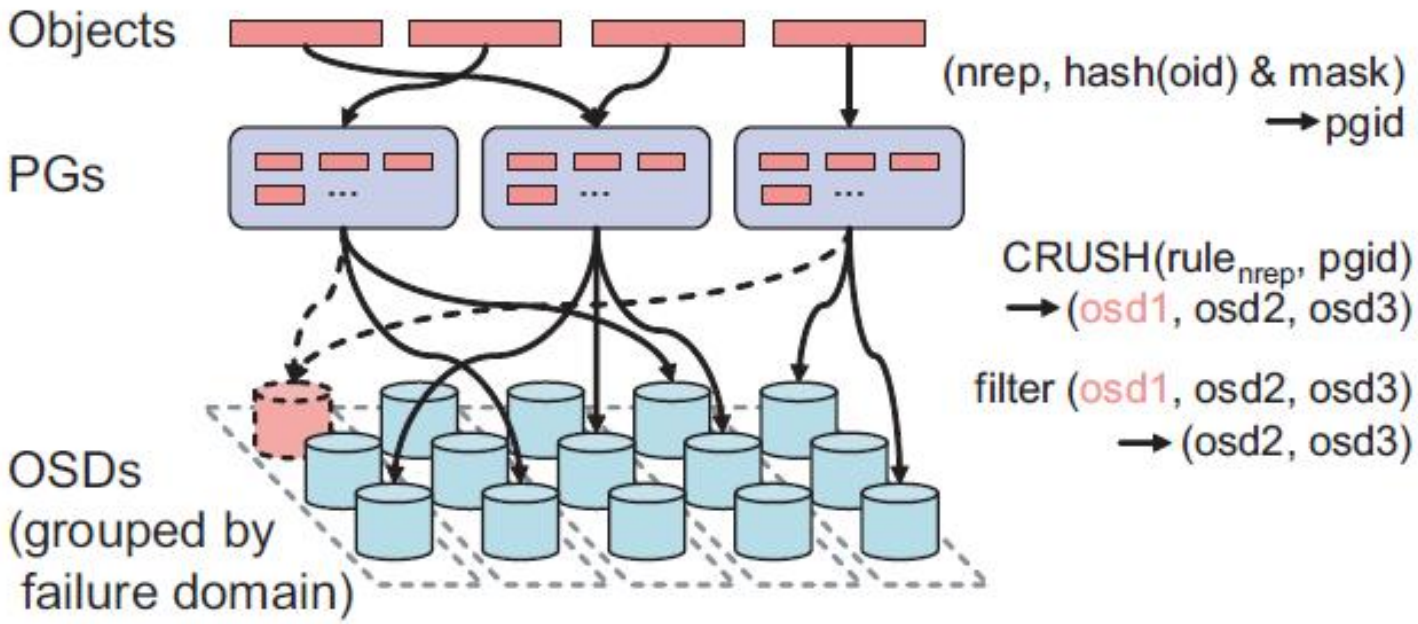
- MDS（Meta Data Server）：用于保存CephFS的元数据。

- PG（Placement Group）：类似于TSSD中一组小表的概念。一个PG由N个OSD组成。N取决于数据存储的份数，一般为2或者3。

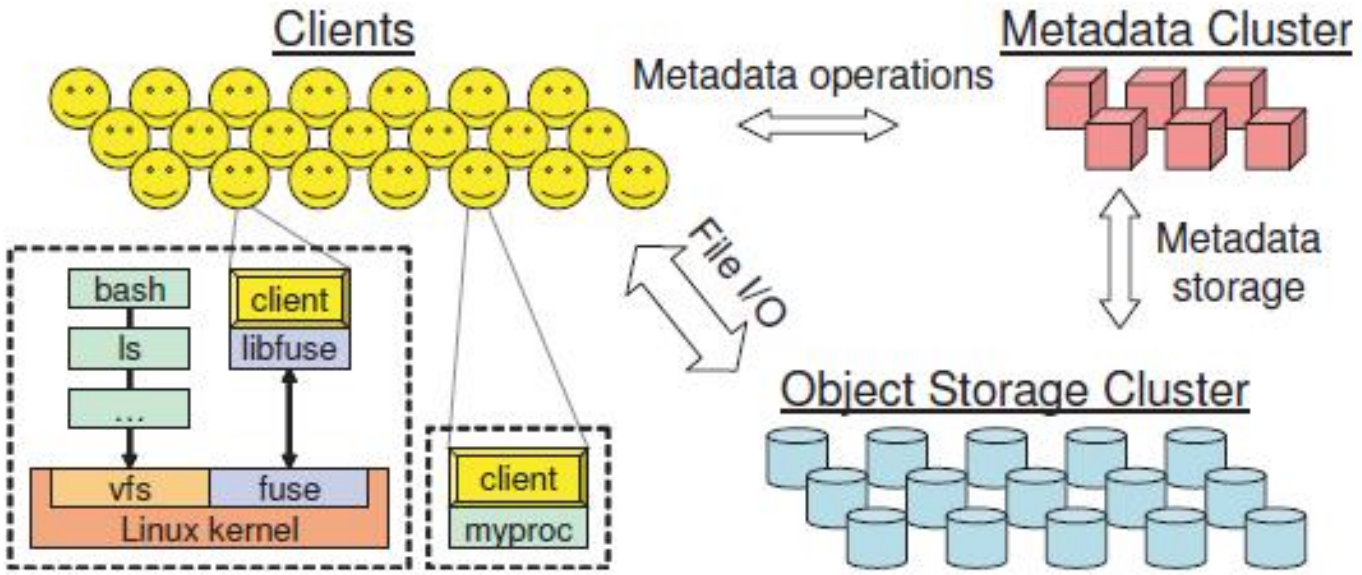
- Pool：存储的逻辑划分区域。由多个PG组成，类似于TSSD中大表的概念。

腾讯网 QQ.com

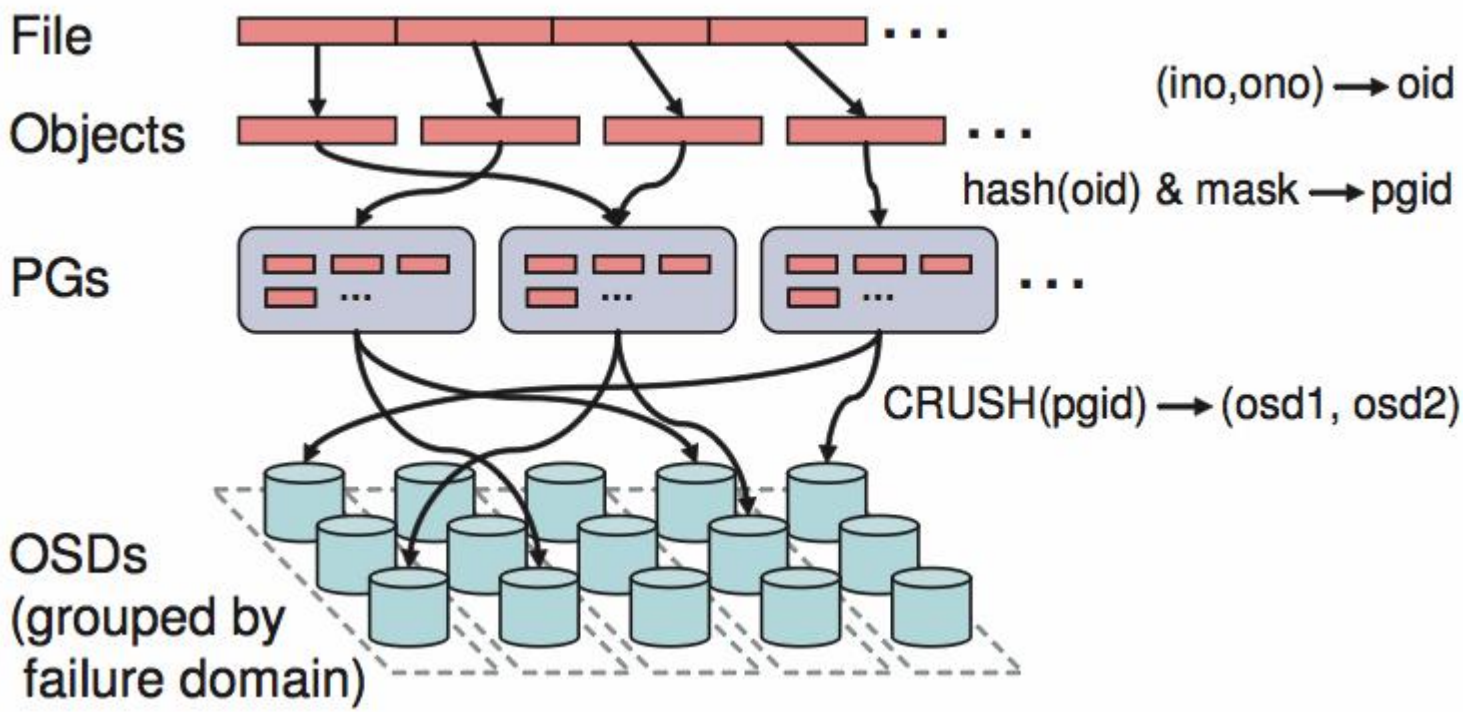
Ceph访问模型--Object存储



Ceph访问模型--FS整体



Ceph访问模型--文件存储



Ceph数据存储

1. ceph存储的逻辑划分是pool， 类似于大表的概念

- pool的属性：Object的副本数， Placement Groups的数量， 所使用的CRUSH RuleSet
- 数据映射方式： (Pool, Object) → (Pool, PG) → OSD set → Disk

腾讯网 QQ.com

Ceph数据存储

2. (Pool, PG) → OSD set的影响因素

- CRUSH算法：一种伪随机算法
- OSD MAP：包含当前所有Pool的状态和所有OSD的状态
- CRUSH MAP：包含当前磁盘、服务器、机架的层级结构
- CRUSH Rules：数据映射的策略。包括pool可以使用的机架，机房，机器等限制

3. 访问流程

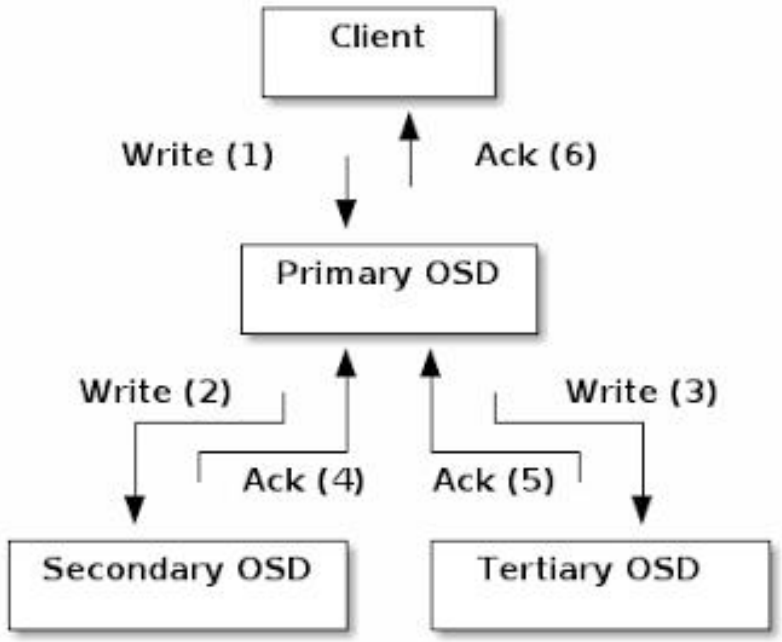
Client从Monitors中得到CRUSH MAP、OSD MAP、CRUSH Ruleset，然后使用CRUSH算法计算出Object所在的OSD set。Ceph不需要保存路由信息的中心节点，Client直接和OSD进行通信

腾讯网 QQ.com

Ceph数据存储--强一致性

4. 数据写的强一致性

- 采用Primary-Replica模型，client负责向primary发送读写请求，每个object只有一个primary。
- primary在收到写请求后负责把数据发送给Replica，所有Replica写成功后才向前端返回成功。



腾讯网 QQ.com

Ceph路由算法--CRUSH

1. Crush概念

CRUSH (Controlled Replication Under Scalable Hashing), a pseudo-random data distribution function that efficiently maps each PG to an ordered list of OSDs upon which to store object replicas.

2. Crush优点

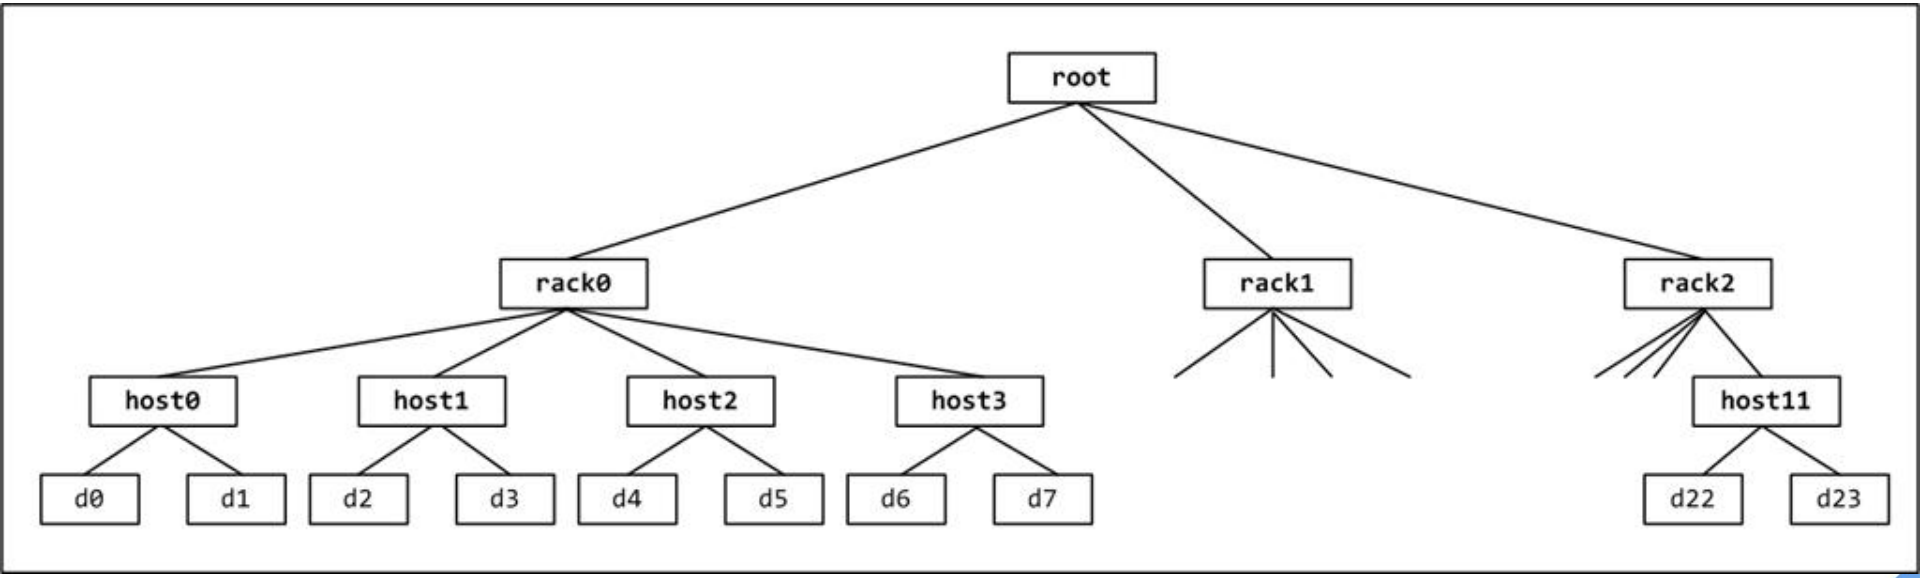
- 无需查表，通过计算得出存储位置
- 客户端不需要保存大量的路由信息
- 可配置的数据分布策略：不同的pool分布在不同机房，机架，存储介质上
- 数据分布比较均匀， 新增加或删除osd时可以保证较少的数据迁移

腾讯网 QQ.com

Ceph路由算法--CRUSH

3. crush map的结构

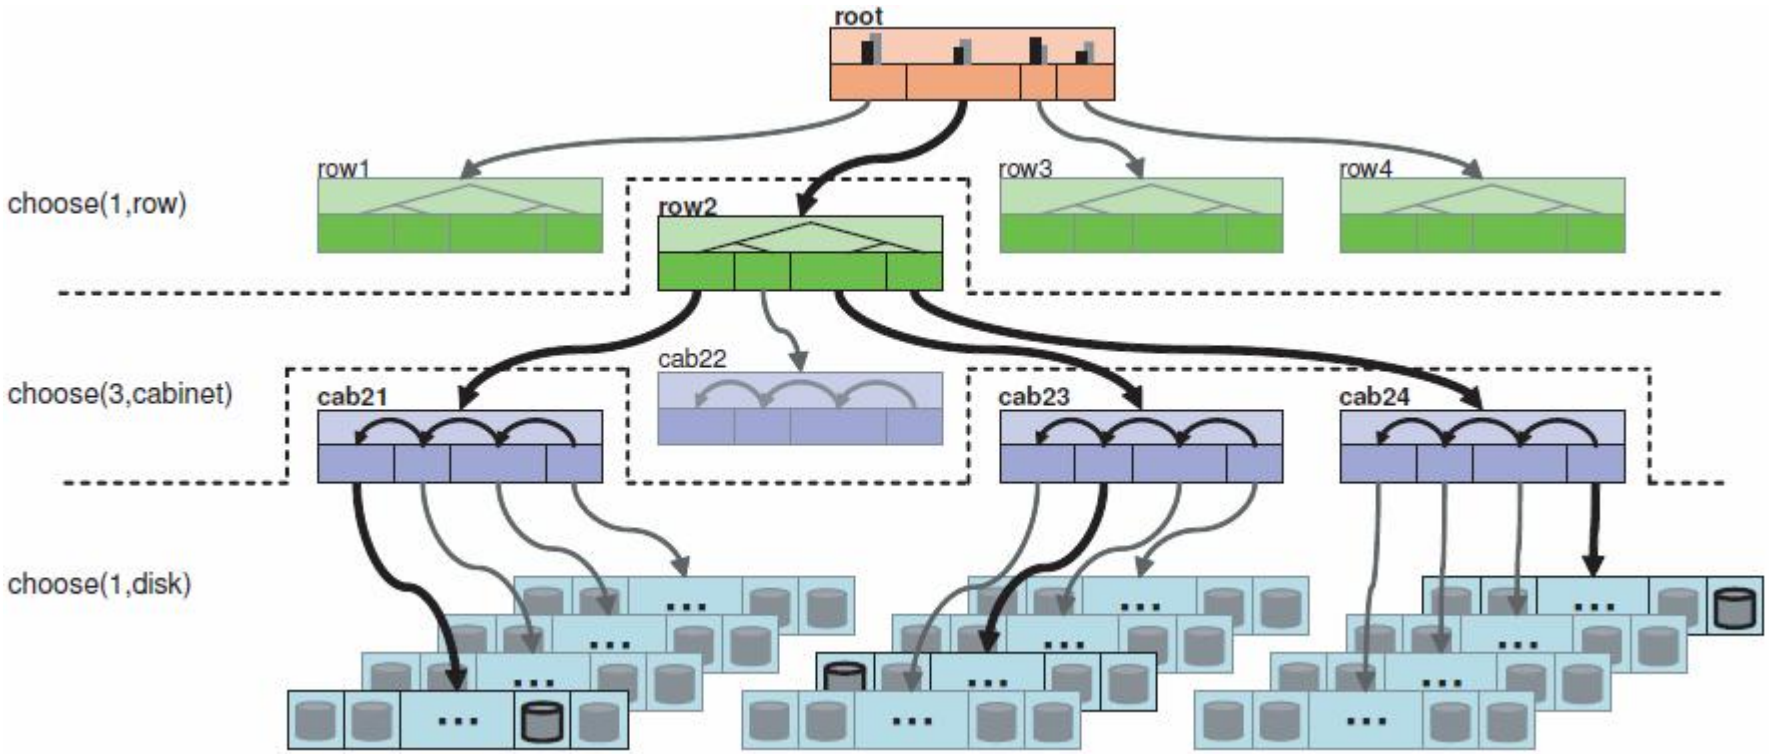
- 图示为3个机架(rack0)，每个机架上有4台主机(host)，每个主机上有2个磁盘(device)



腾讯网 QQ.com

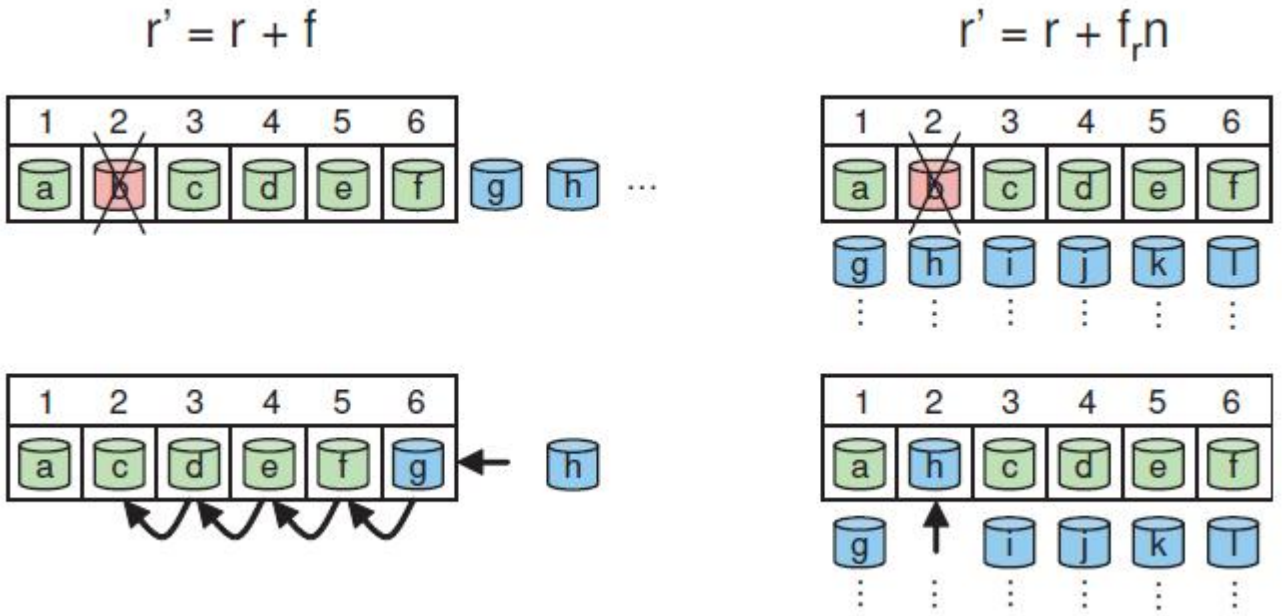
Ceph路由算法--CRUSH

4. OSD的查询过程



Ceph路由算法--CRUSH

5. OSD选择



Ceph容错性

1. 常见故障：网络中断、掉电、服务器宕机、硬盘故障等。Ceph能够容忍这些故障，并进行自动修复。

- Monitors是Ceph管家，维护着Ceph的全局状态。Monitors的功能和zookeeper类似，它们使用Quorum和Paxos算法去建立全局状态的共识。
- OSDs可以进行自动修复，而且是并行修

2. 故障探测

- OSD之间有心跳检测，当OSD A检测到OSD B没有回应时，会报告给Monitors说OSD B无法连接，则Monitors给OSD B标记为down状态，并更新OSD Map。当过了M秒之后还是无法连接到OSD B，则Monitors给OSD B标记为out状态(表明OSD B不能工作），并更新OSD Map。
- Monitor之间会同步OSD的状态信息

腾讯网 QQ.com

Ceph容错性

3. 故障恢复

- 当OSD set中有一个OSD被标记为down时(假如是Primary被标记为down，则某个Replica会成为新的Primary，并处理所有读写 object请求)，则该PG处于active+degraded状态。

- 标记为down的机器在M秒后仍然无法连接，则被标记为out状态。Ceph会重新计算PG到OSD set的映射

- 新OSD set的Primary先从旧的OSD set中收集PG log，得到一份Authoritative History(完整的、全序的操作序列)，并让其他Replicas同意这份Authoritative History(也就是其他Replicas对PG的所有objects的状态达成一致)，这个过程叫做Peering。

- 当Peering过程完成之后，PG进 入active+recoverying状态，Primary会迁移和同步那些降级的objects到所有的replicas上，保证这些objects 的副本数为N

腾讯网 QQ.com

Ceph和TSSD以及CBS的对比

	TSSDV3	CBS3.0	Ceph
中心路由结点	有	有	无
故障探测恢复	外围探测，外围恢复	自动探测加恢复，外围可介入	自动探测和恢复
数据均衡方式	外围工具	外围工具	自动
接入机	有	有	有
强一致性	是	是	是
最大存储容量	2P（100万*2G）	2P（100万*2G）	无理论最大值
存储数据类型	key-value	key-vale	支持key-value，file，block

腾讯网 QQ.com

Ceph和TSSD以及CBS的对比

1. 我们的优势

- 核心系统代码自主设计实现， 对生产系统的可控性强
- 贴近公司业务，结合公司的业务和机型优化存储系统， 为业务提供更好的体验
- 运营经验丰富，对整个存储平台的可控性较强。

2. ceph中的学习点（个人观点）

- 了解ceph file system的实现方式，提高对云计算和云存储的认识
- 了解ceph中的故障探测方式，并思考可以借鉴的地方
- 了解ceph中快照的创建和使用方式，使用场景， 结合CBS的快照系统，加深对快照的理解
- 延伸了解openstack， swift， amazon S3， docker等云计算中比较流行的系统， 开阔眼界。

腾讯网 QQ.com