# TSSD存储利用率提升方案

ghostwydwu(武勇栋)

腾讯网
QQ.com

# 目录


项目背景

- 面临的运营问题
- 项目目标
- 项目收益
- 备选方案
- 总体方案

详细方案

- 存储引擎优化
- 平台资源管理
- 平台动态调度
- 平台其他优化

实施计划


腾讯网 QQ.com

# 项目背景 — 面临的运营问题

## 业务在TSSD平台上的存储利用率低

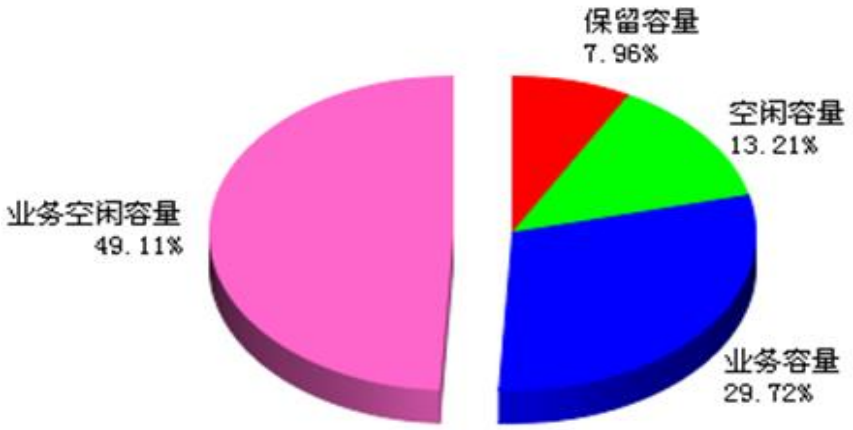
目前仅有30%的存储利用率

原因：

小表内存储利用率低

空闲容量多

存在保留容量




数据采集于：【架构平台部—运营日报】【结构化存储—TSSD平台】[2015—03—09]

## 单小表空间分布

单小表2GB，保留容量500MB

| 分类 | 不可回收 | 腾挪空间 | 可回收碎片 | 总量 |
|---|---|---|---|---|
| 容量 | 400MB | 20MB | 80MB | 500MB |

预留100MB作为小表扩容的实施过程中（警戒线）的增长（1.4GB）

另有200MB作为小表扩容前资源筹备期（预警）的业务增长（1.2GB）

**目前小表在1.2GB（60%）的时候会进行容量预警；分裂扩容后，存储利用率降低到30%，所以小表内存储利用率低。**

腾讯网 QQ.com

# 项目背景—项目目标

## 提升存储利用率

目标存储利用率达到60%

## 高效扩容模式

支持业务的快速扩容，减少扩容带来的数据搬迁

允许少量扩容，降低因为扩容带来的利用率大幅下降

腾讯网 QQ.com

# 项目背景—项目目标

**提升存储利用率：**目标存储利用率达到60%

单小表可伸缩1.5GB->3GB，3GB的小表保留容量600MB

| 分类 | 不可回收 | 腾挪空间 | 可回收碎片 | 总量 |
|---|---|---|---|---|
| 容量 | 450MB | 30MB | 120MB | 600MB |

预留250MB作为扩容的自然增长，则2.15GB开始需要进行分裂

小表内存储利用率>67%（供平台存储利用率）：

| 单小表说明 | 业务数据(GB) | 分配空间(GB) | 利用率 |
|---|---|---|---|
| 触发分裂 | 2.15 | 3 | 71% |
| 系统上限 | 2.4 | 3 | 80% |
| 分裂后场景1 | 1.07 | 1.5 | 71% |
| 分裂后场景2 | 1.2 | 1.5 | 80% |
| 分裂后继续增长（利用率最低） | 1.35 | 2 | 67% |

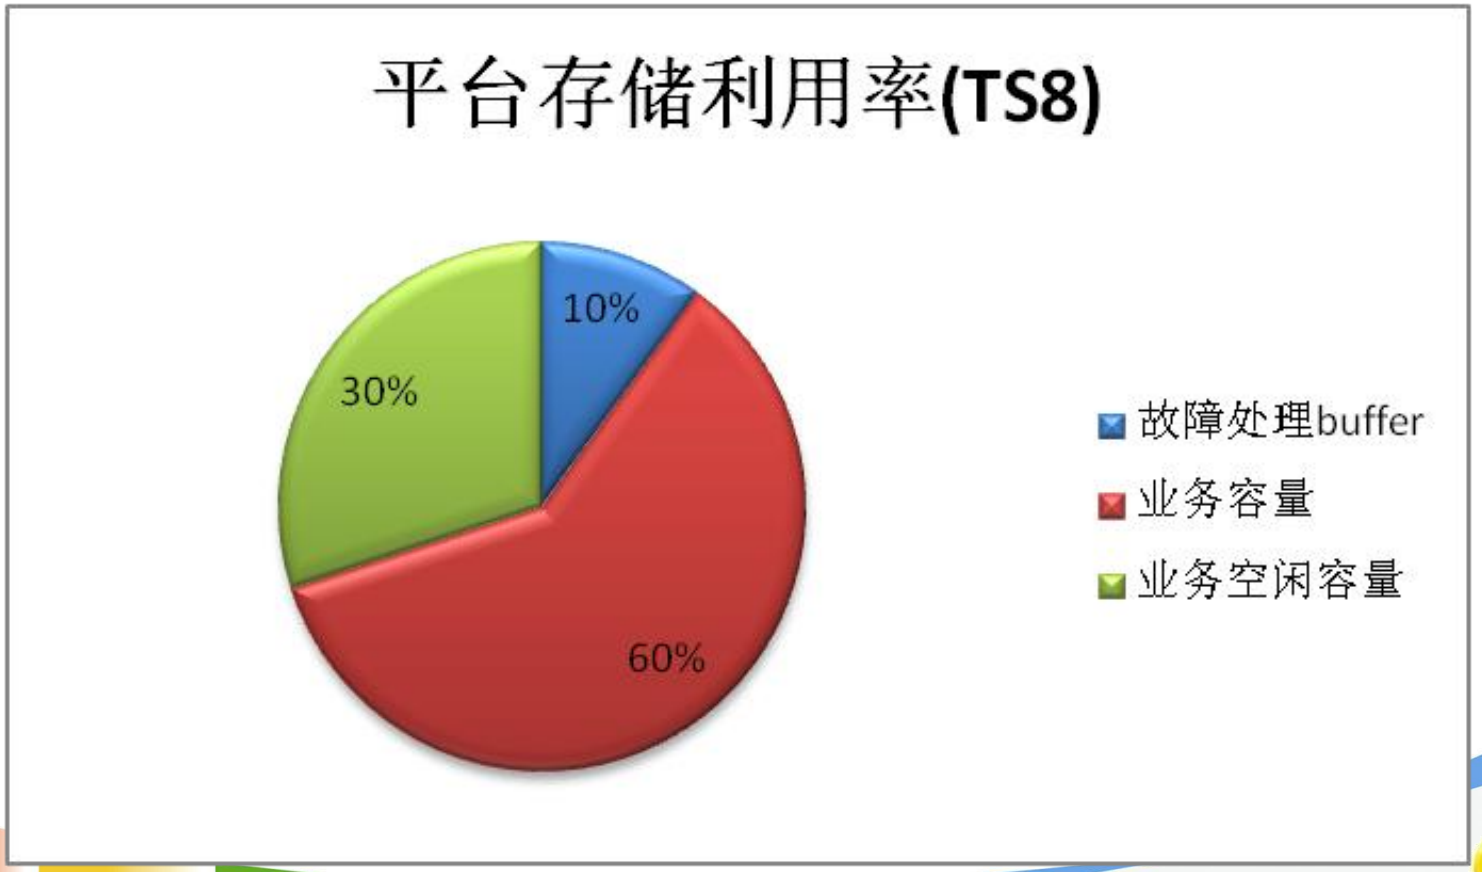
腾讯网 QQ.com

# 项目背景—项目目标

**提升存储利用率：** 目标存储利用率达到60%

故障buffer 10% ：单SET10组，其中保留 1组机器作为故障处理buffer

平台利用率60%：分配给业务90%*小表内存储利用率67%




腾讯网 QQ.com

# 项目背景—项目收益

## 预期收益

在现有存储量上，节约2087台TS8

预计TSSDV3未来一年增长：2657台；升级到TSSDV5后，可以抵消增长！

| 时间 | 平台 | 业务容量(TB) | 物理存储量(TB) | 机器数（TS8) | 利用率 |
|---|---|---|---|---|---|
| 2015-01 | TSSDV3 | 3804 | 12610 | 4201 | 30% |
| | TSSDV5 | 3804 | 6340 | 2114 | 60% |
| 2016-01 | TSSDV3 | 6209 | 20585 | 6858 | 30% |
| | TSSDV5 | 6209 | *10349* | 3450 | 60% |

PS： 1．机器数根据现有物理存储量折算成TS8

2．业务增量是根据2014~2015一年增长量63%估算

腾讯网 QQ.com

# 项目背景—竞品对比

## 竞品成本对比

TSSDV5利用率最高

TSSDV5 单位成本仅高于微信朋友圈存储，低于其他平台

| 平台 | TS8存储量(TB) | 利用率 | 单份成本(￥/GB/月) | 存储份数 | 单位成本(￥/GB/月) |
|---|---|---|---|---|---|
| 微信-Quorum_KV(朋友圈) | 1.5 | 50% | 1.32 | 2 | 2.64 |
| TSSDV5 | 1.8 | 60% | 1.1 | 3 | 3.3 |
| 微信-Quorum_KV(消息) | 0.9 | 30% | 2.2 | 2 | 4.4 |
| 互娱-TCAPLUS | 0.43(Z3) | 26% | 2.43 | 2 | 4.86 |
| 即通-grocery_SSD | 1.2 | 40% | 1.65 | 3 | 4.95 |
| TSSDV3 | 0.9 | 30% | 2.2 | 3 | 6.6 |

腾讯网 QQ.com

# 项目背景—备选方案

## 现有多规格扩容方案

多次数据搬迁才能达到扩容目的

扩容速度慢

## 按SET部署方案

**添加索引后带来的成本上升（索引存储在MEM）【2014-01数据】**

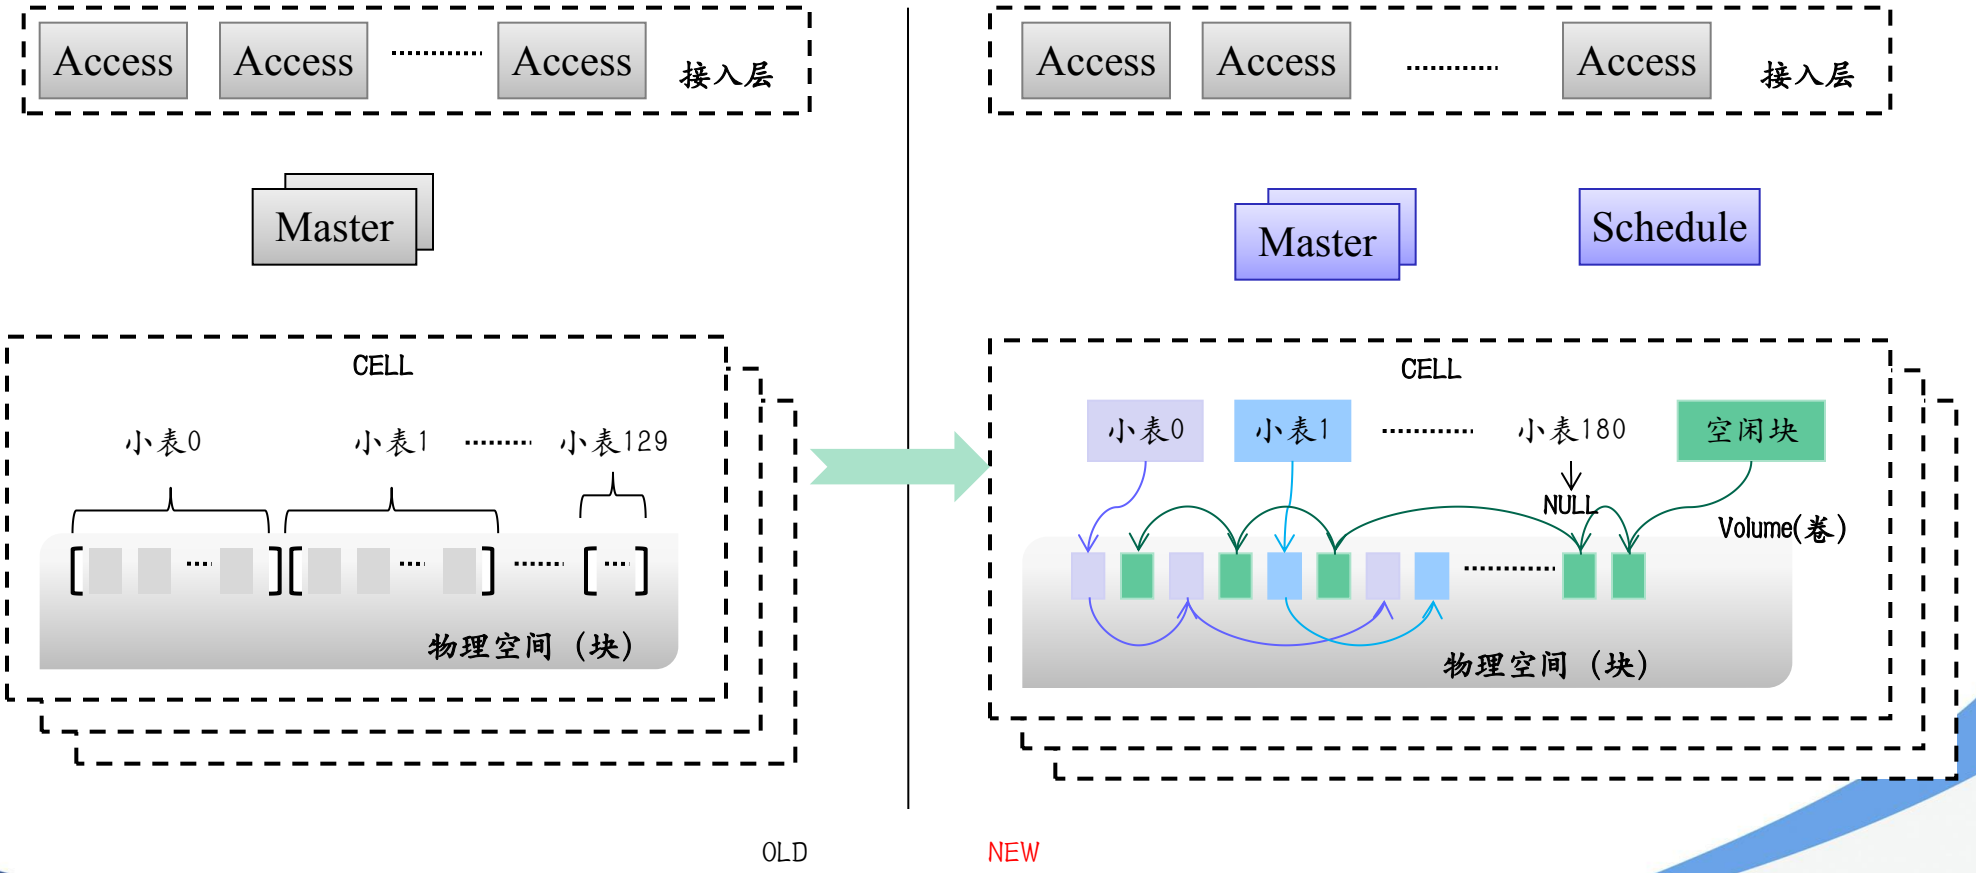
| 平均记录分类 | 业务数 | 数据量TB | 数据占比 | 需要TS8机器 | 记录数(亿) | 索引 | | | 索引/数据成本比 | 按SET部署总TS8设备数 | 现有TS8机器数 |
|---|---|---|---|---|---|---|---|---|---|---|---|
| | | | | | | 容量GB | B6机器数 | 折合TS8 | | | |
| <4KB | 290 | 325 | 0.4 | 582 | 22209.27 | 41367 | 2758 | 1562 | 2.68 | 2144 | 1098 |
| >4KB | 35 | 472 | 0.59 | 846 | 406.9313 | 757 | 52 | 29 | 0.03 | 875 | 1479 |
| <1KB | 254 | 269 | 0.33 | 483 | 21909.13 | 40808 | 2722 | 1542 | 3.19 | 2025 | 924 |
| >1KB | 71 | 527 | 0.66 | 945 | 707.0654 | 1317 | 88 | 49 | 0.05 | 994 | 1650 |
| 总数 | 325 | 796 | 1 | 1428 | 22616.2 | 42125 | 2810 | 1591 | 1.11 | 3019 | 2574 |

表格前提： 1. 索引长度20B；2.B6数据量30GB，两份存储；3.B6 TCO成本1150,TS8 TCO成本2030；
4. 按SET部署平均存储利用率达60%

腾讯网 QQ.com

# 项目背景—总体方案

- 小表空间动态伸缩
  - 提高扩容后小表存储利用率



# 项目背景—总体方案

## 数据的动态调度

$$\text{存储利用率} = \frac{\text{业务容量} \searrow}{\text{使用硬盘容量} \nearrow}$$

为了提升存储利用率，采取小表使用的硬盘容量动态伸缩的方法，来解决扩容带来的存储利用率变化的问题。

## 伸缩范围——卷（volume）

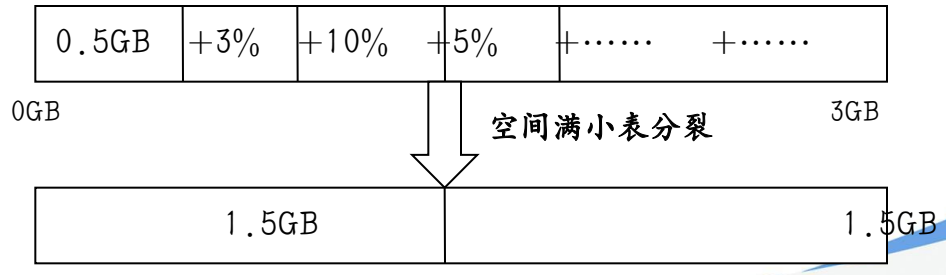
将连续的279GB硬盘空间作为一个逻辑卷，由一个cell进程单独管理，master管理的物理容量最小单元

卷中有180个逻辑小表，可用的硬盘容量在0~3GB之间，平均每个小表硬盘容量1.5GB

## 小表伸缩

小表的分裂不会增加物理空间

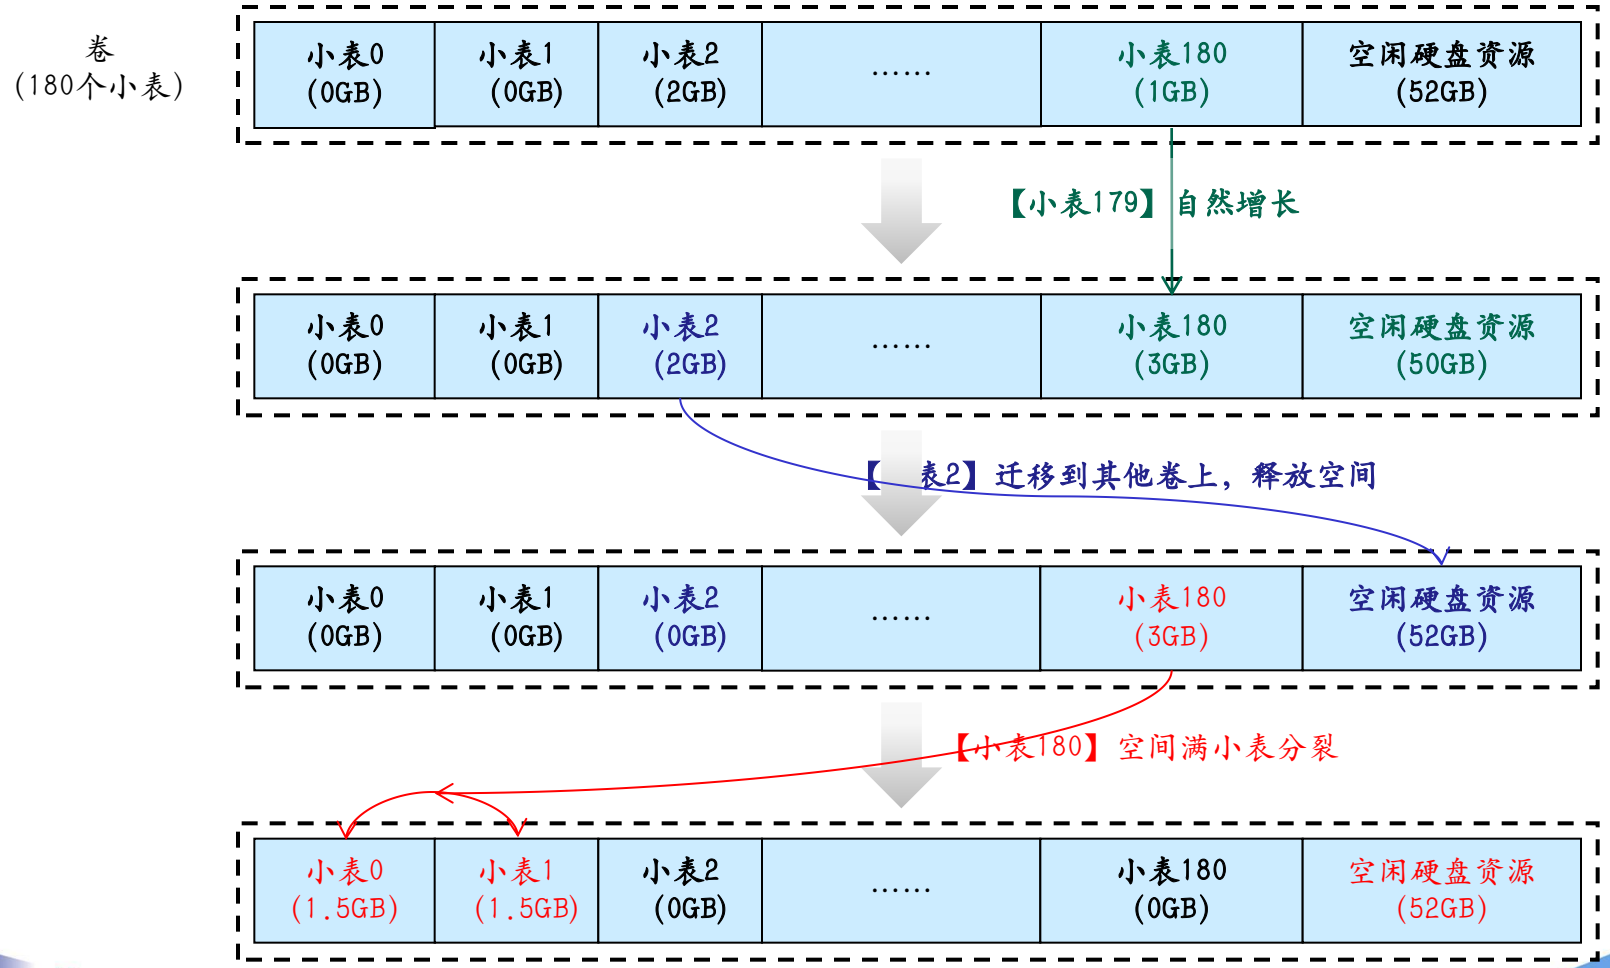
分裂不影响存储利用率




腾讯网 QQ.com

# 详细方案—存储层优化

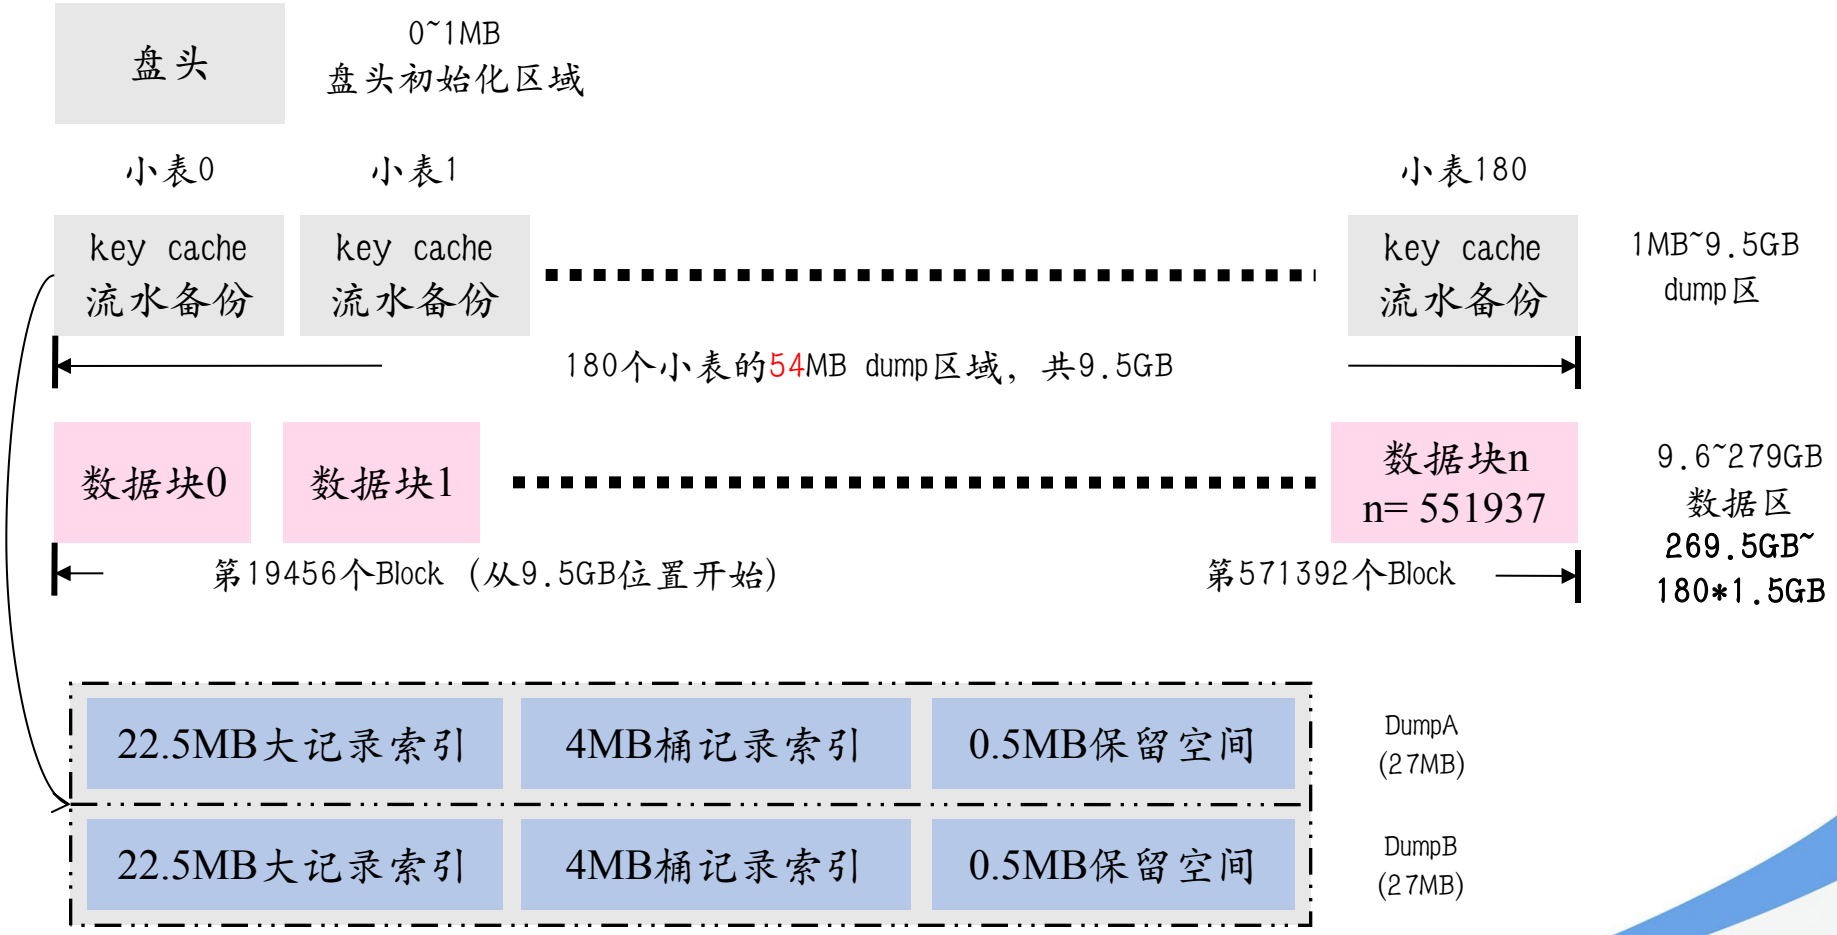
## 卷管理




腾讯网 QQ.com

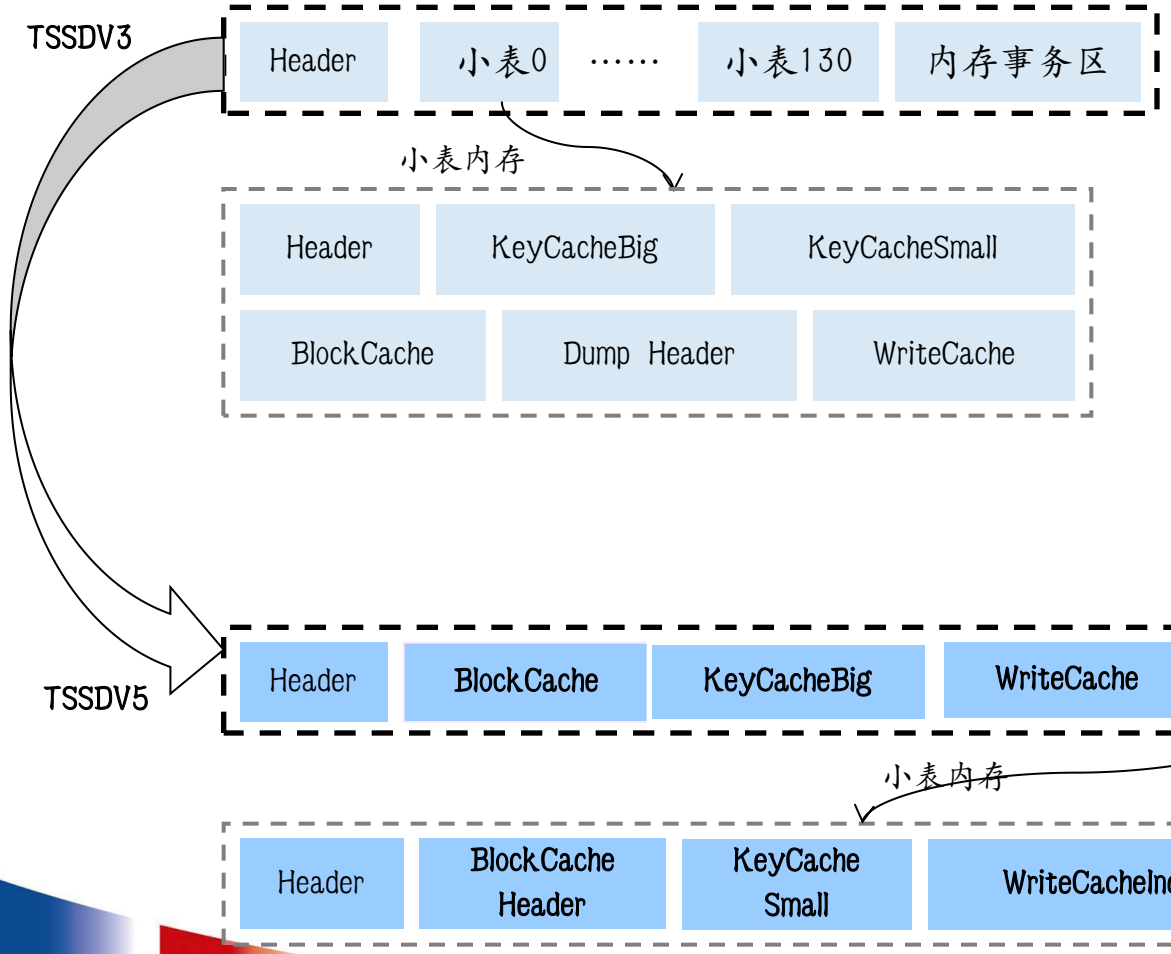
# 详细方案—存储层优化

## 卷内硬盘数据组织：



# 详细方案—存储层优化

## 内存分布对比



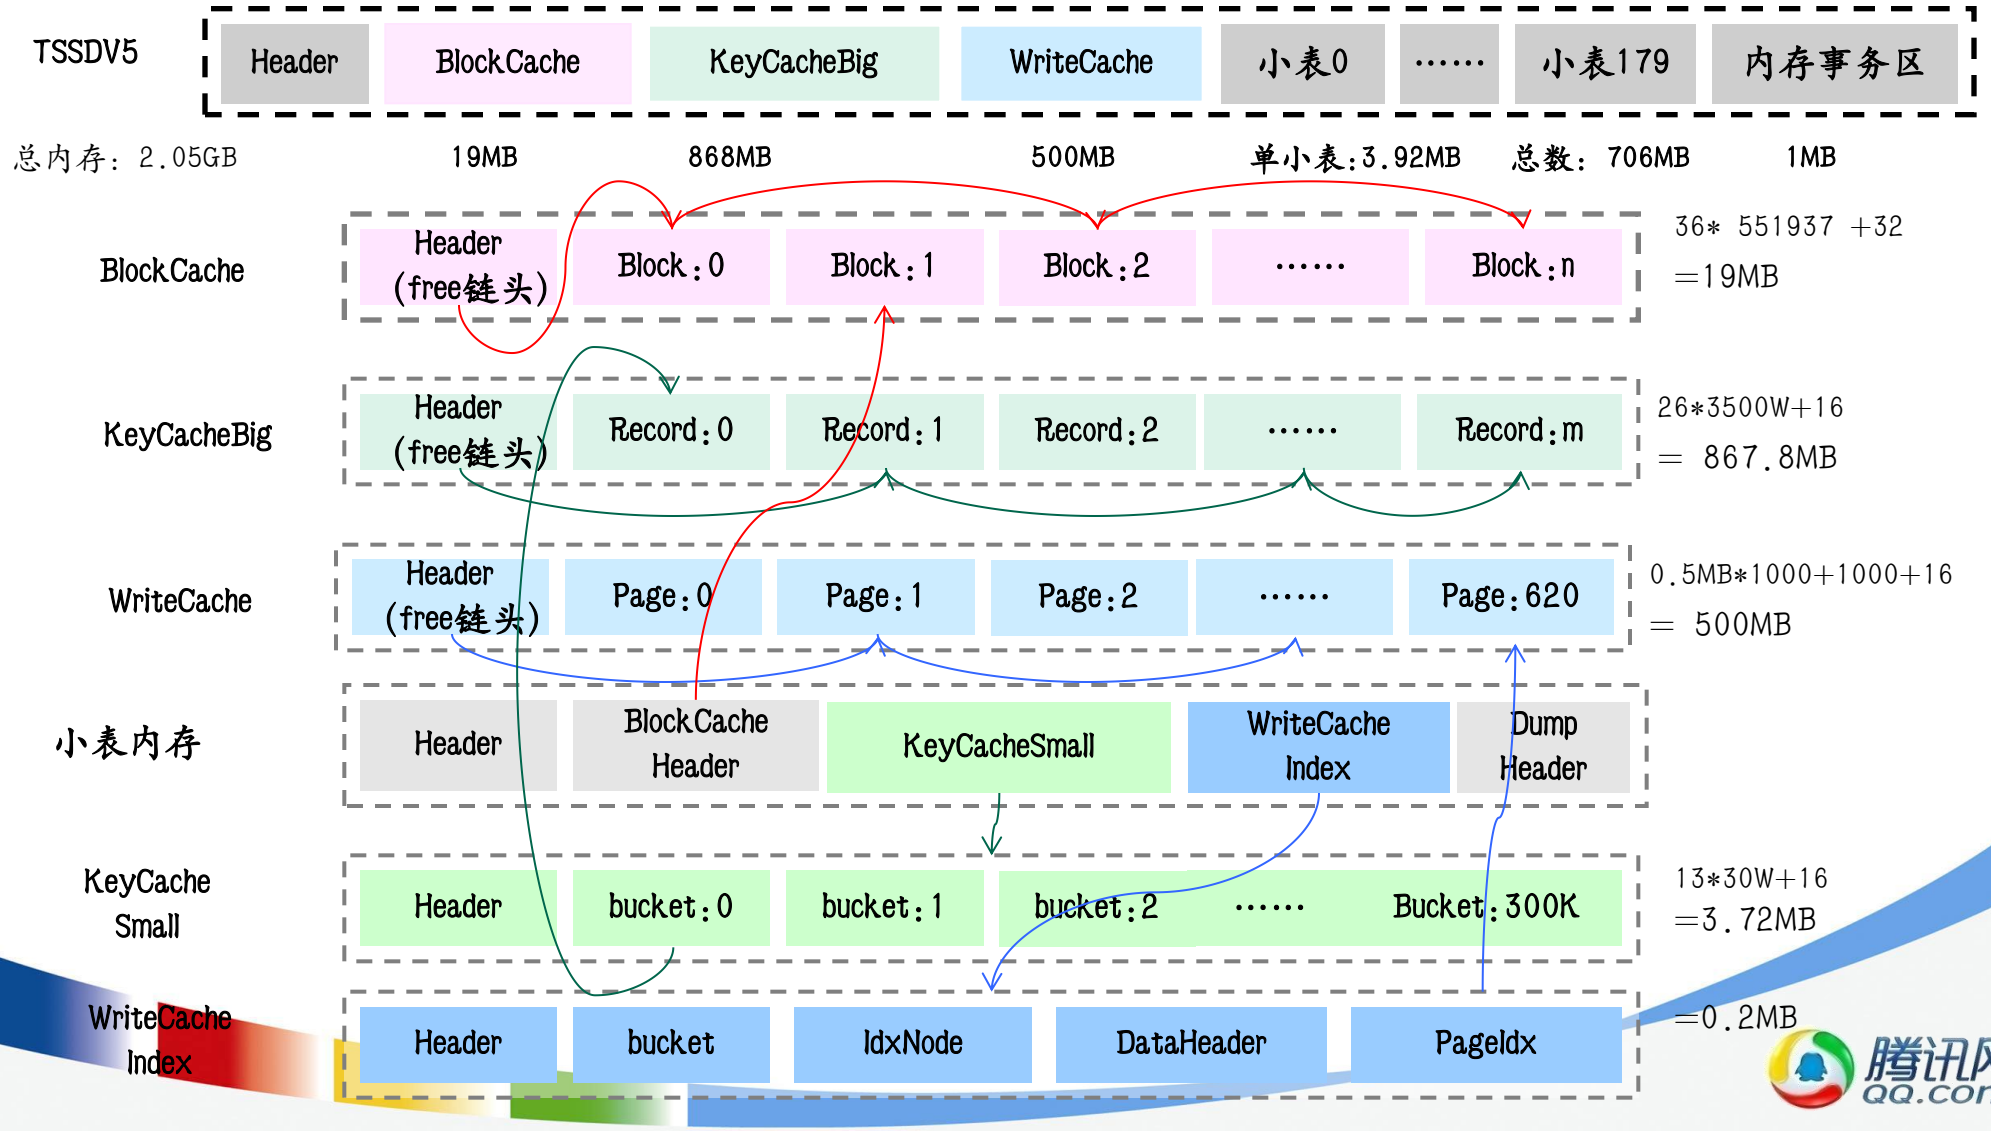

对比：

- **BlockCache**:全局管理，小表内保存链表、统计信息
- **KeyCache**:
  - KeyCacheBig总空间变大，且采用全局管理，小表内保存链表的形式
  - KeyCacheSmall仍在小表内管理
- **WriteCache**：数据区全局管理，小表内管理索引信息

腾讯网 QQ.com

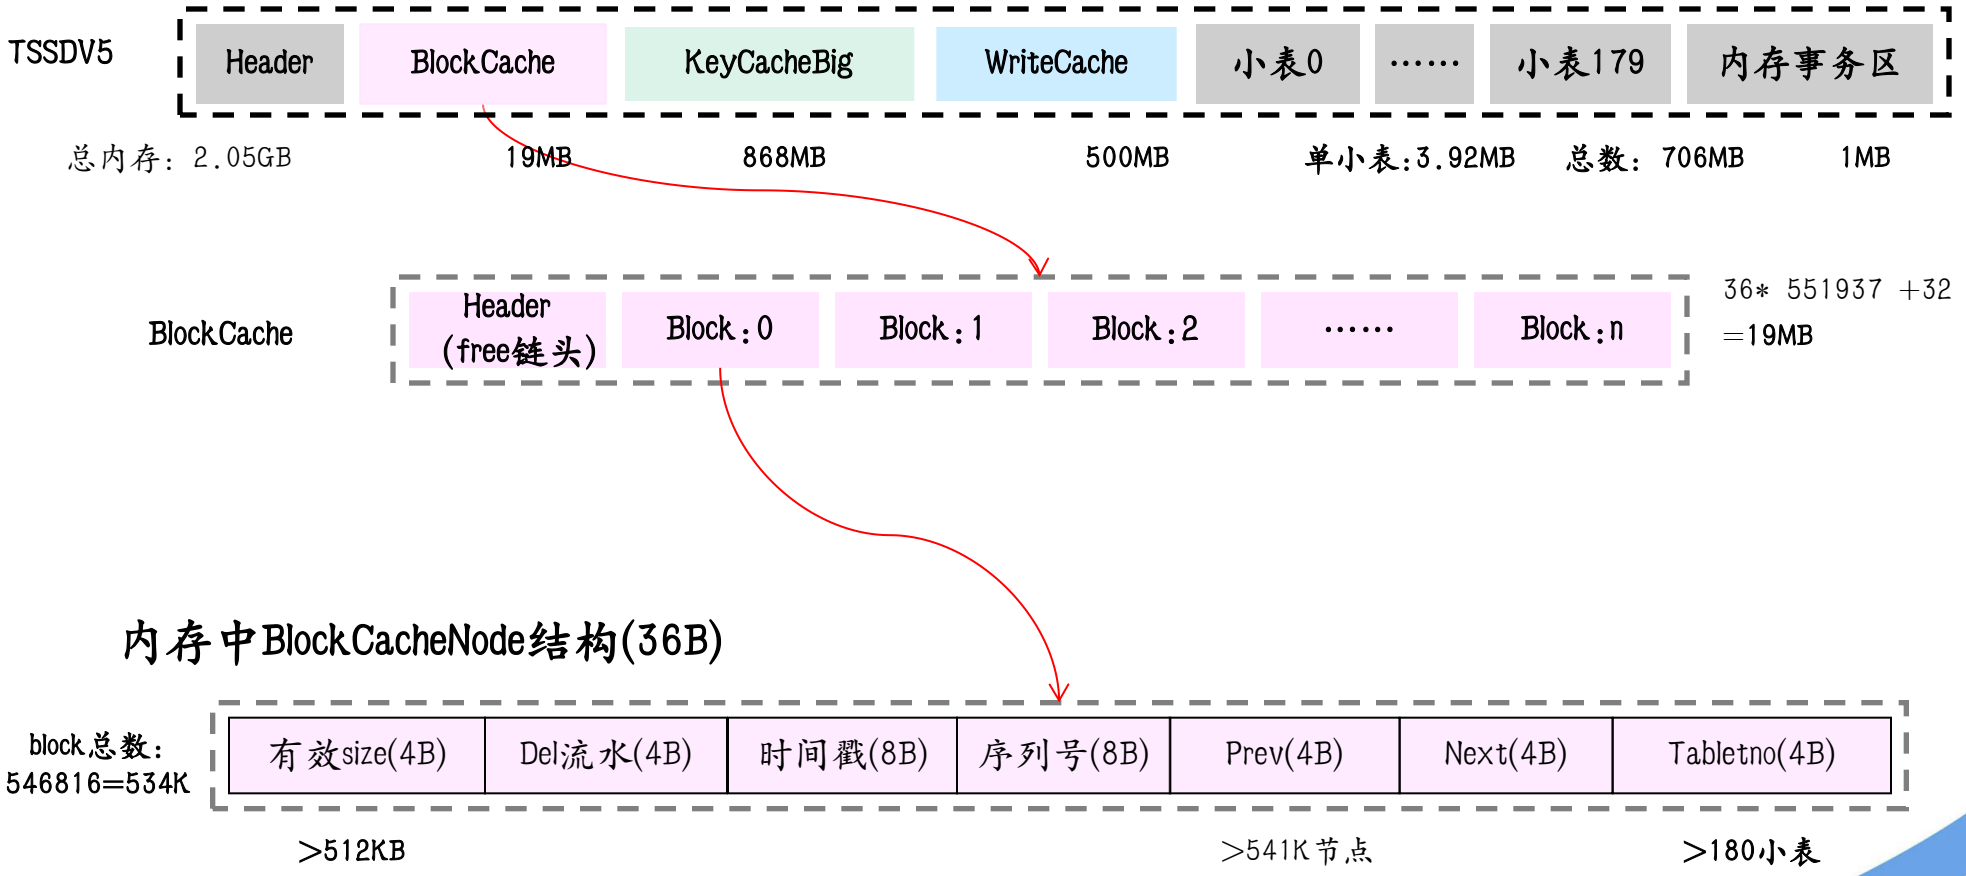
# 详细方案—存储层优化

## 内存分布



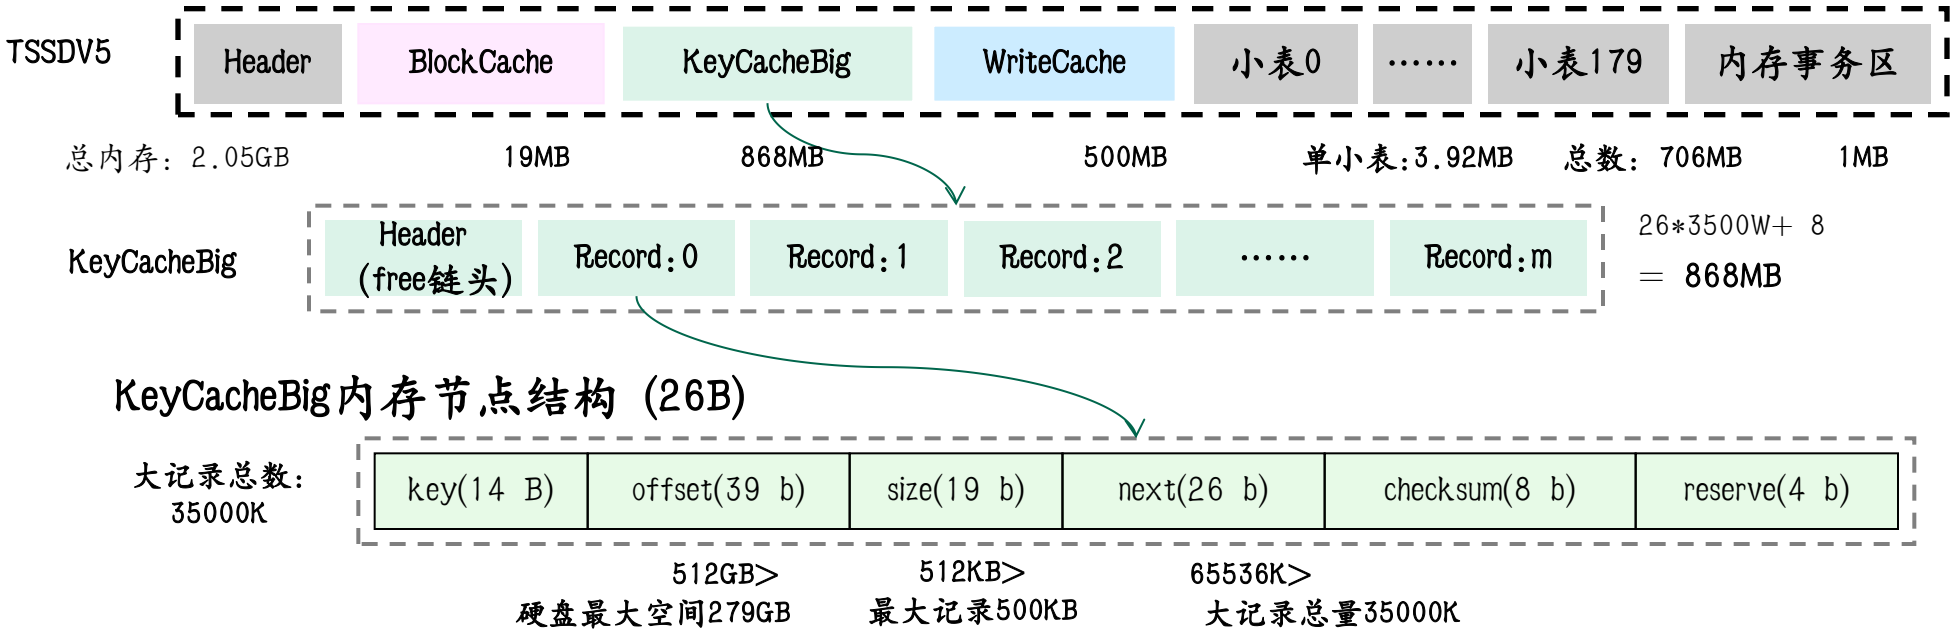
# 详细方案—存储层优化

## 内存分布



# 详细方案—存储层优化

## 内存分布




## Qzone平台业务，大记录场景分析：

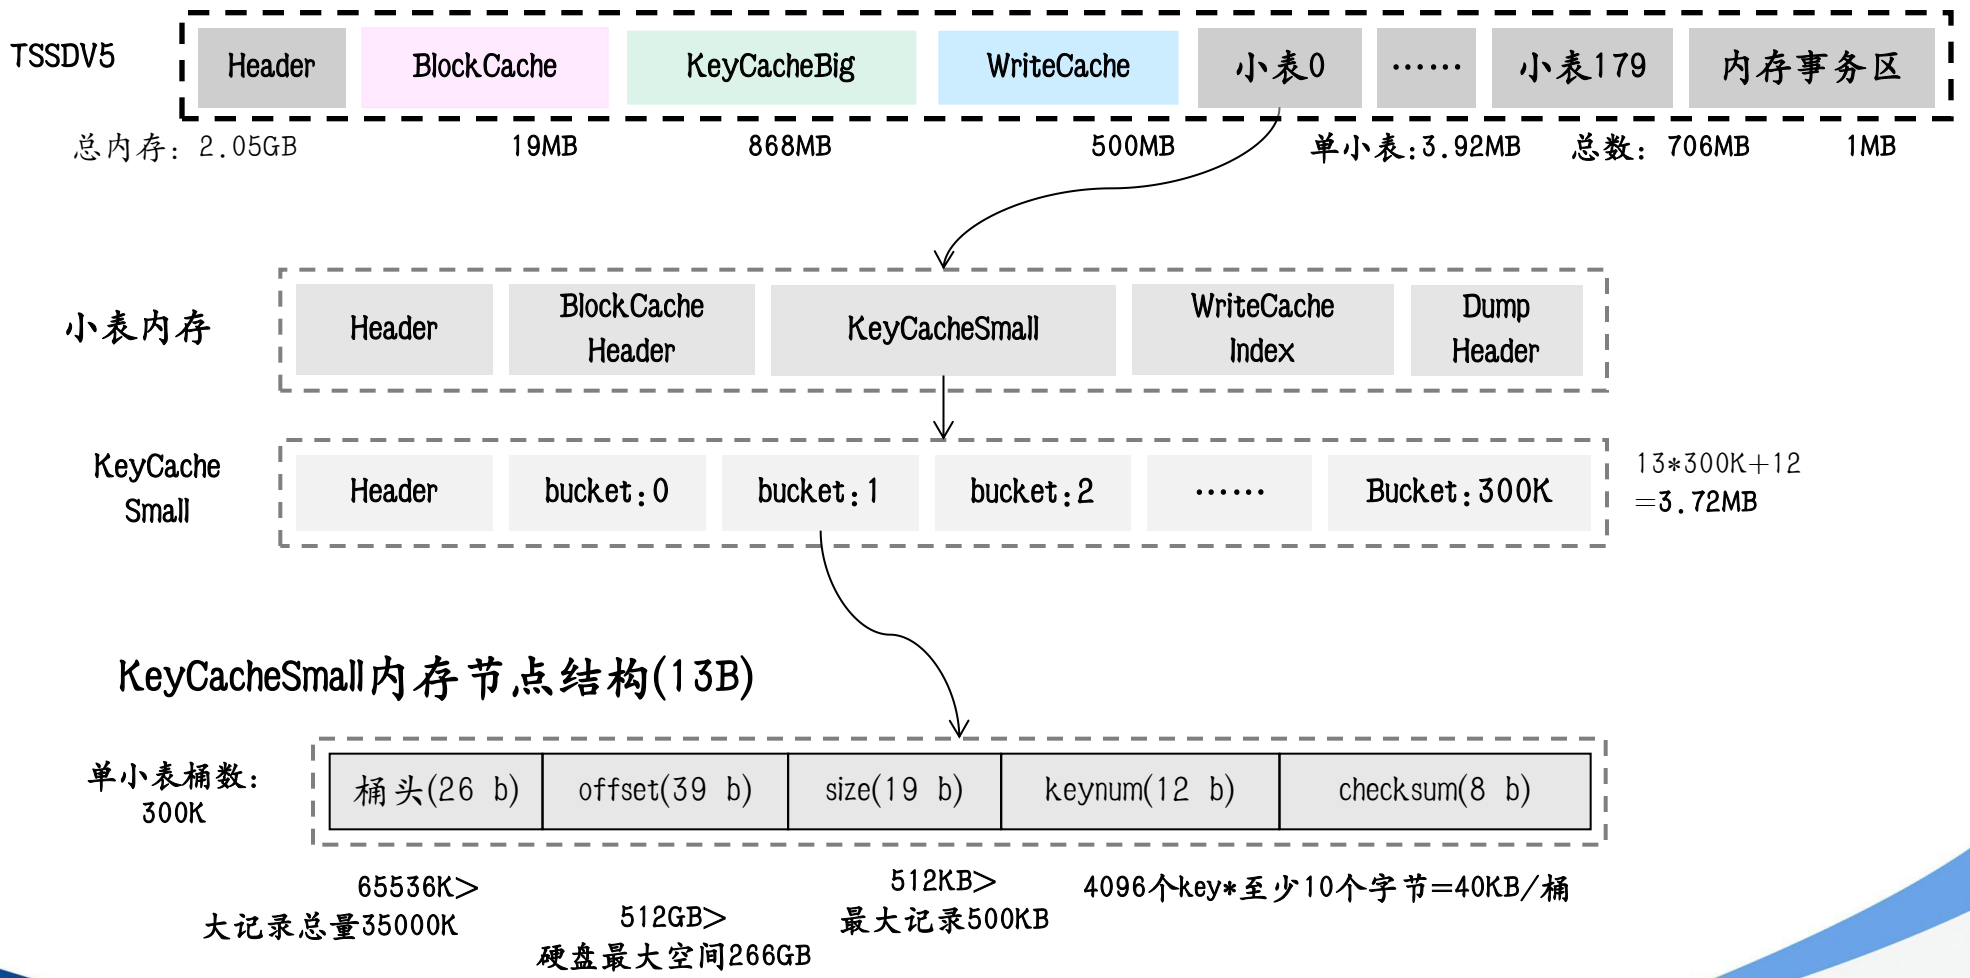
| 平均记录(KB) | 业务数据(TB) | 数据比例 | 业务数 | 上限存储利用率 |
|---|---|---|---|---|
| [4,5] | 6.56 | 0.67% | 6 | 50%～62% |
| [5,6] | 18.84 | 1.93% | 3 | 62%~74.4% |
| 总量 | 975 | | 372 | |

1. 大记录场景适用于99%的业务；
2. 部分平均记录大小4~5KB的业务可通过与其他业务混存，提高存储利用率。

腾讯网 QQ.com

# 详细方案—存储层优化

## 内存分布



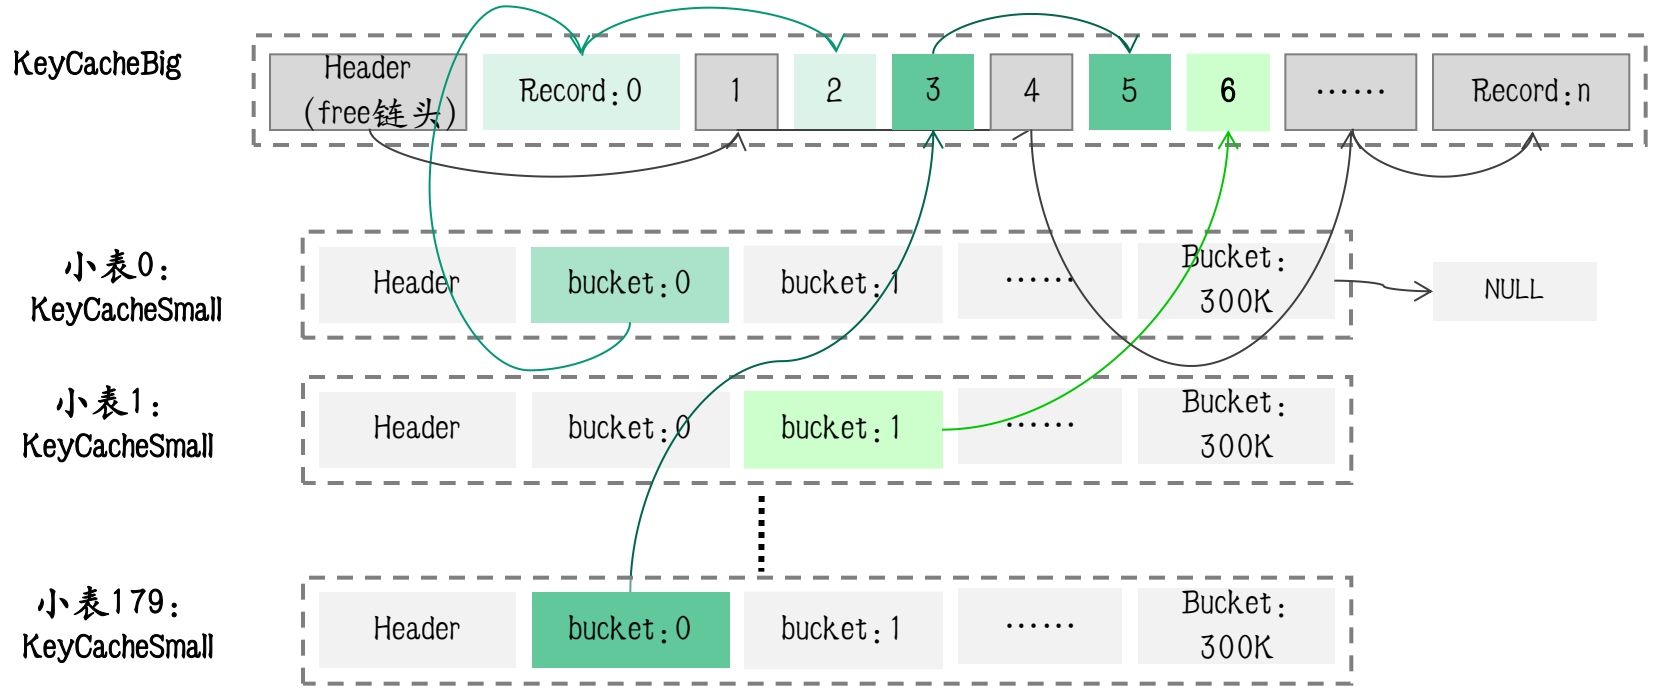
# 详细方案—存储层优化

- **KeyCache内存结构**
  - 随着存储利用率提升，原有的内存索引结构不再适用
    - KeyCacheBig单小表只能存储1.2GB（大记录4KB时，300K个节点），无法存放更多数据
  - **新的调整：**
    - KeyCacheBig: 资源统一管理，小表按需申请（类似BlockCache），允许单小表申请更多的节点

腾讯网 QQ.com

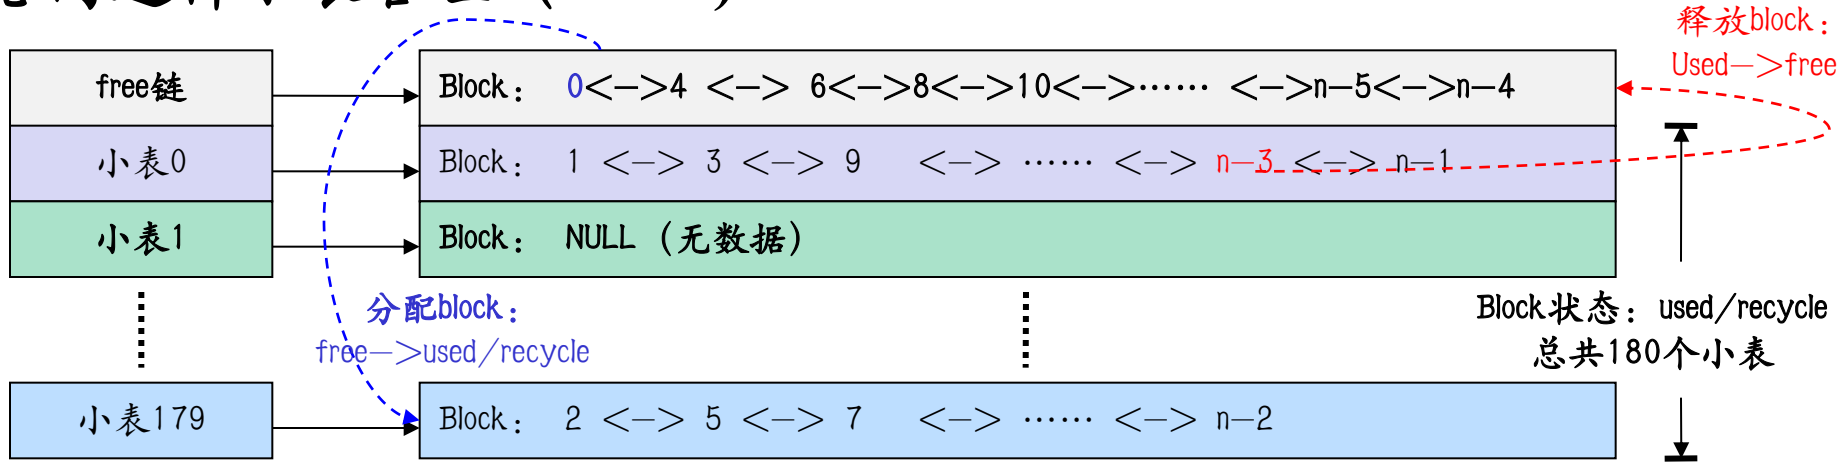
# 详细方案—存储层优化

## 卷内逻辑小表管理（KeyCache）

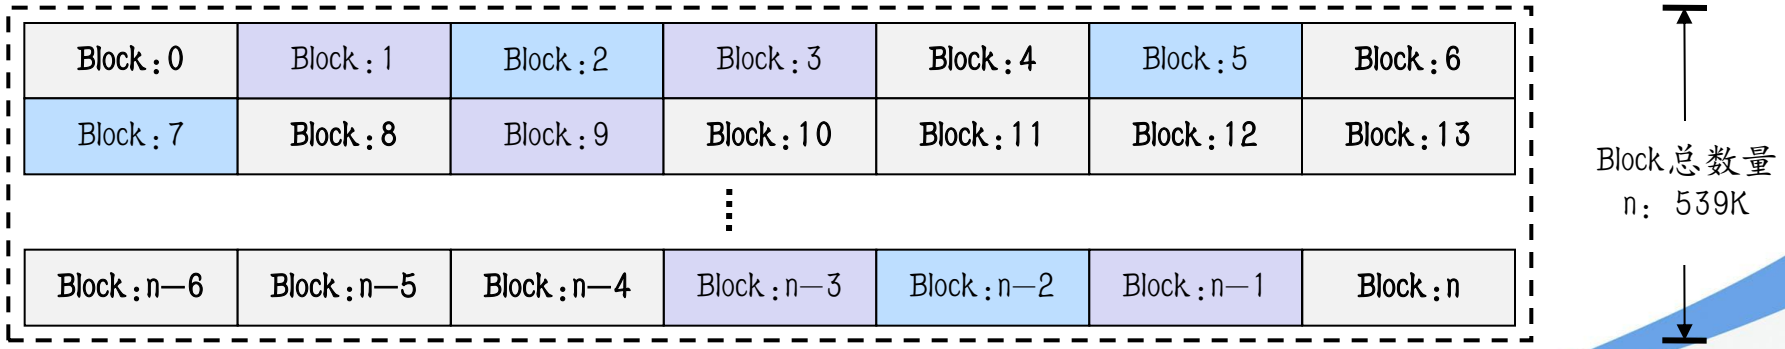


# 详细方案—存储层优化

## 卷内逻辑小表管理（Block）

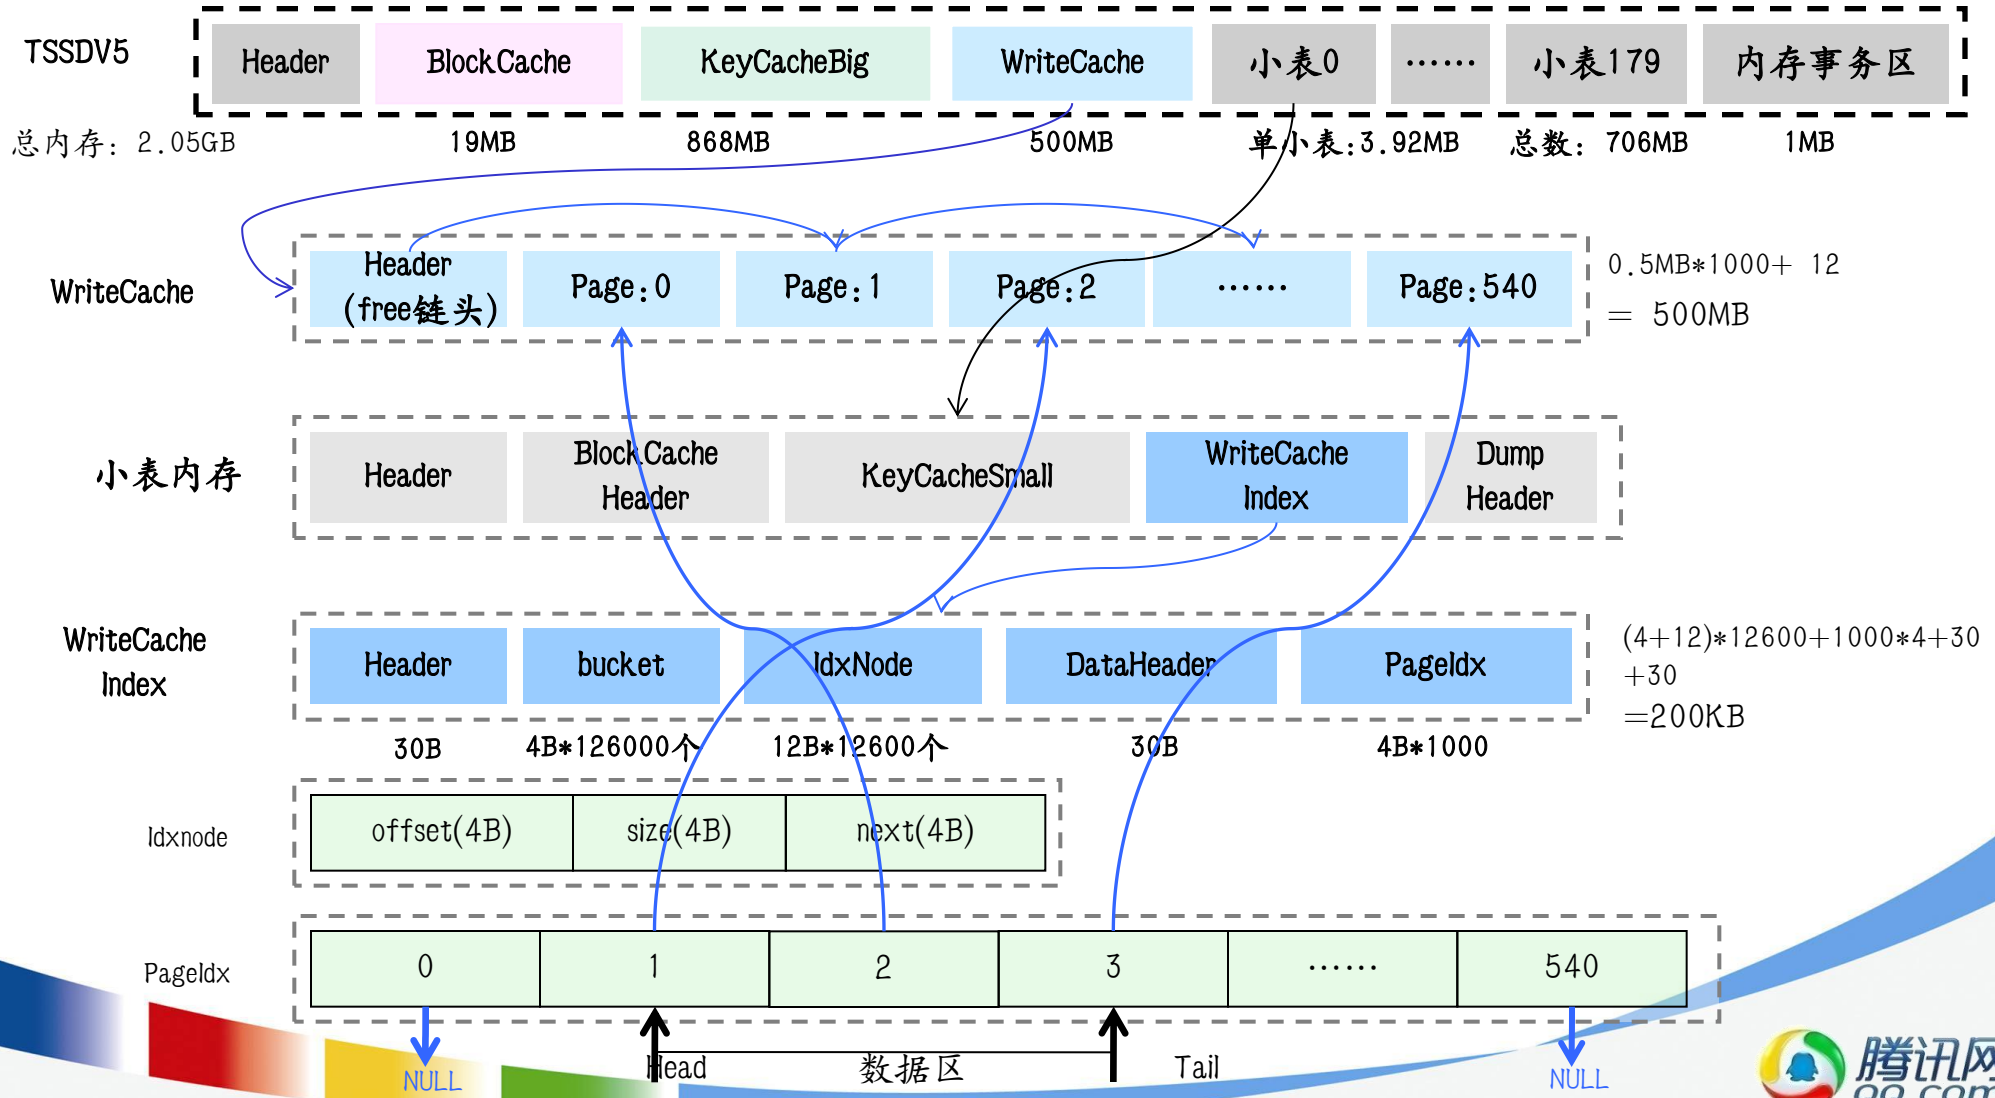



其中卷的硬盘中所有块如下图所示：



# 详细方案—存储层优化

## WriteCache的设计(内存分布)



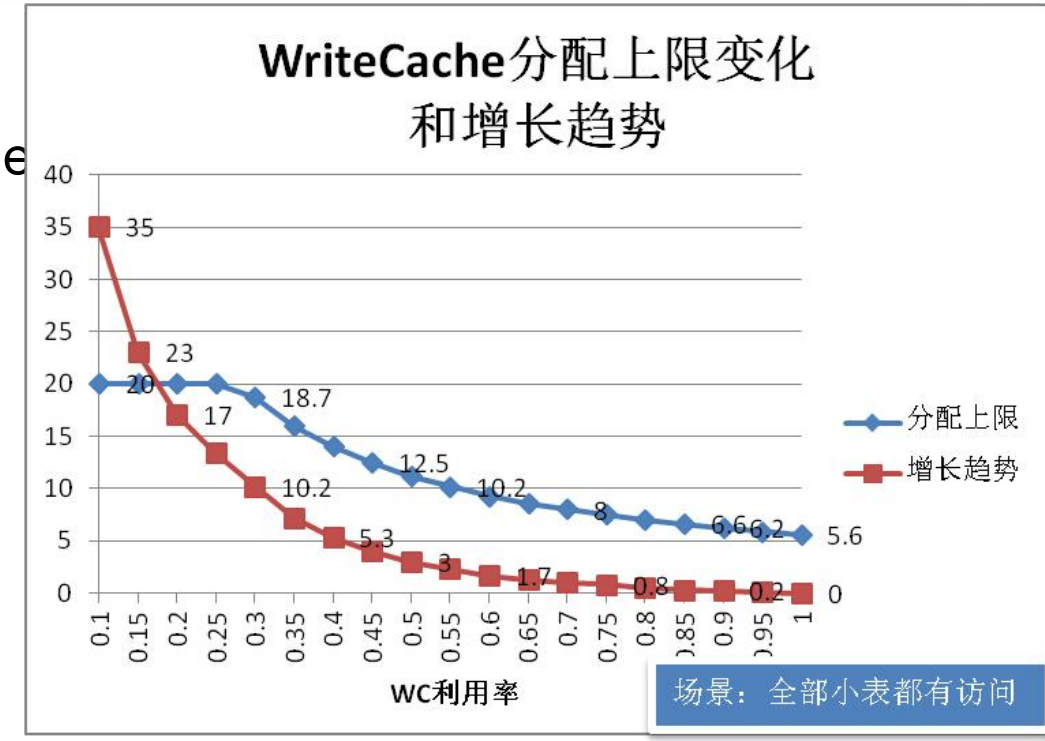
# 详细方案—存储层优化

- **索引持久化：定点dump**
  - 在写线程中，遍历小表的KeyCache内存，将内存索引数据分批落盘；
  - 多小表dump点分散
- **Block落地时，带所属小表信息**
- **数据恢复策略：dump+扫盘恢复**
  - 扫描全盘，得到每个小表的block列表和恢复顺序
  - 逐个小表恢复内存：
    - 选择dump：最新的完整dump
    - 扫描硬盘： 将dump点后的block数据按照时间先后顺序恢复到KeyCache中
    - 恢复blockcache： keycache中数据在block上的分布情况
    - 校验：抽样校验dump点前的Block的数据是否和KeyCache对应，异常打印日志信息
    - 在小表服务开关打开前，关闭写（合并、回收）

腾讯网 QQ.com

# 详细方案—存储层优化

- **WriteCache内存分配策略**
  - 预留：为每个空小表预留1个Page
  - 最多：20个Page
  - 迁移：写目标wc时，分配无限制




- 分配影响因素：
  - 总小表数——有数据小表数
  - 当前资源的使用情况 ——WC使用率 = 已分配数 / (总数-预留数)

$$\text{上限值} = \min\left(20, \frac{\text{WC总数} - (\text{总小表数} - \text{有数据小表数}) * 1}{\text{有数据小表数} * \text{WC使用率}}\right)$$

# 详细方案—存储层优化

## 数据块分配策略

每个小表上限3GB的空间，即6000个数据块

## 支持小表回收接口

用于将小表所使用的数据块和大记录索引释放到空闲池，供再利用

添加路由校验和无访问校验，保证回收的准确、安全

腾讯网 QQ.com

# 详细方案—存储层优化

## IO调度策略

小表间：公平轮询调度

小表内：合并写、回收写的分配

合并写——受WC的利用率影响，越高越需要调度

回收写——受小表内利用率

和 是否即将达到小表上限3GB（块分配率） 两个因素影响

回收写：合并写比例

| 列\行：WC分配率 | | 0~33% | 33~66% | >66% |
|---|---|---|---|---|
| 块分配率 | 小表利用率 | | | |
| >0.8 | <60% | 3:1 | 3:2 | 3:3 |
| | 60~80% | 2:1 | 2:2 | 2:3 |
| | 80~100% | 1:1 | 2:2 | 1:2 |
| <=0.8 | <60% | 2:1 | 3:2 | 3:3 |
| | 60~80% | 1:1 | 2:2 | 2:3 |
| | 80~100% | 1:1 | 2:2 | 1:2 |

腾讯网 QQ.com

# 详细方案—平台资源管理 (master)

**主要负责卷、小表的资源使用信息采集及资源分配控制**

**Master资源信息**

**Master中管理的最大粒度为卷（volume）,卷包涵的资源：**

小表（180个小表）

硬盘数据块Block

内存大记录索引KeyCacheBig（节点）

**Master从卷的心跳中，获取下列信息：**

每个小表的资源统计信息

空闲Block的个数、Block总数

空闲KeyCacheBig的个数、KeyCacheBig总数

上述统计信息为小表的分配的考虑因数之一

腾讯网 QQ.com

# 详细方案—平台资源管理 (master)

## Master资源管理

### 上架卷（注册卷）

带有cellip、smcd、小表个数

### 下架卷

检查卷上所有小表都未被使用（状态为free)
且卷被标记为不可用

### 小表分配

**规则：**目标卷有足够的资源，包括空闲的小表、free块、未使用的KeyCacheBig个数；

**分配步骤：**

a. 接收到占位请求，包括指定ip、smcd（可无）、申请的块个数、KeyCacheBig个数

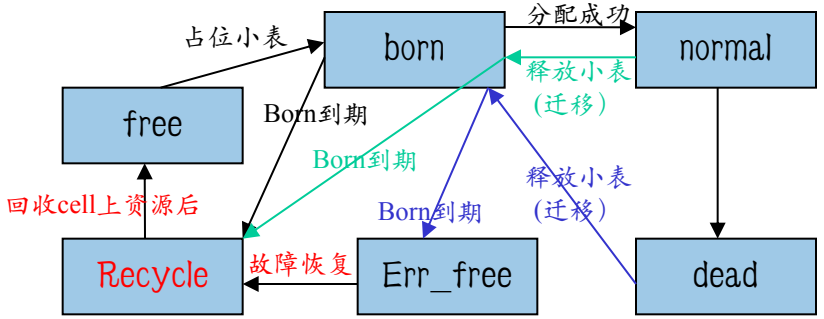
b. master内部资源占位，包括小表的born、卷内空闲资源的占位（free block、free keycachebig)

c. 分配结束， 结束资源预占位

腾讯网 QQ.com

# 详细方案—平台资源管理 (master)

## 小表状态变化




### 小表回收

master对于recycle小表，向cell发起回收请求，成功将状态改成free

若存在路由不一致的情况，不允许进行recycle小表回收、free小表分配

## BUFFER预留策略（小表、卷内资源）

死机坏盘的容灾需要10%的buffer，此资源包括free小表、free块、空闲KeyCacheBig；（需要运维手段保证）

业务自然增长需要10%的buffer，此资源包括free块、空闲KeyCacheBig；为了便于管理，减少迁移，此限制附加与卷。（Master)

# 详细方案—平台动态调度(Schedule)

## Schedule调度场景

均衡： a. 卷满，出现卷>80% && 卷利用率差异>2%

b. 大表均衡，存在大表不均衡的情况，差值大于10%

分裂：小表业务数据>=2GB

迁移： a. 小表状态为Dead（死机/坏盘）

b. 卷不可用（下架）

腾讯网 QQ.com

# 详细方案—平台动态调度(Schedule)

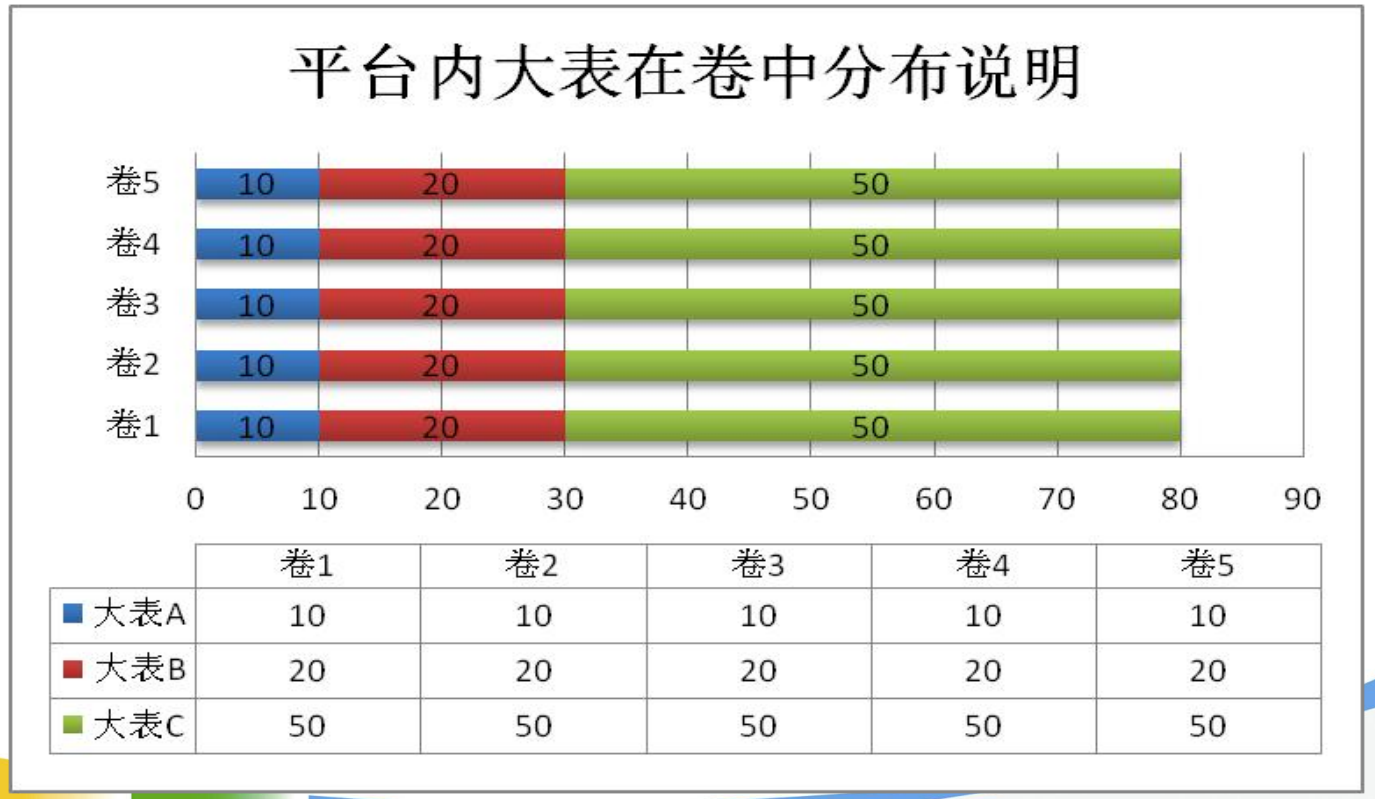
## 平台稳态

所有卷**存储利用率相同**——同比例的空闲buffer供业务增长

所有卷**大表的分布情况相同**:

业务同比例增长

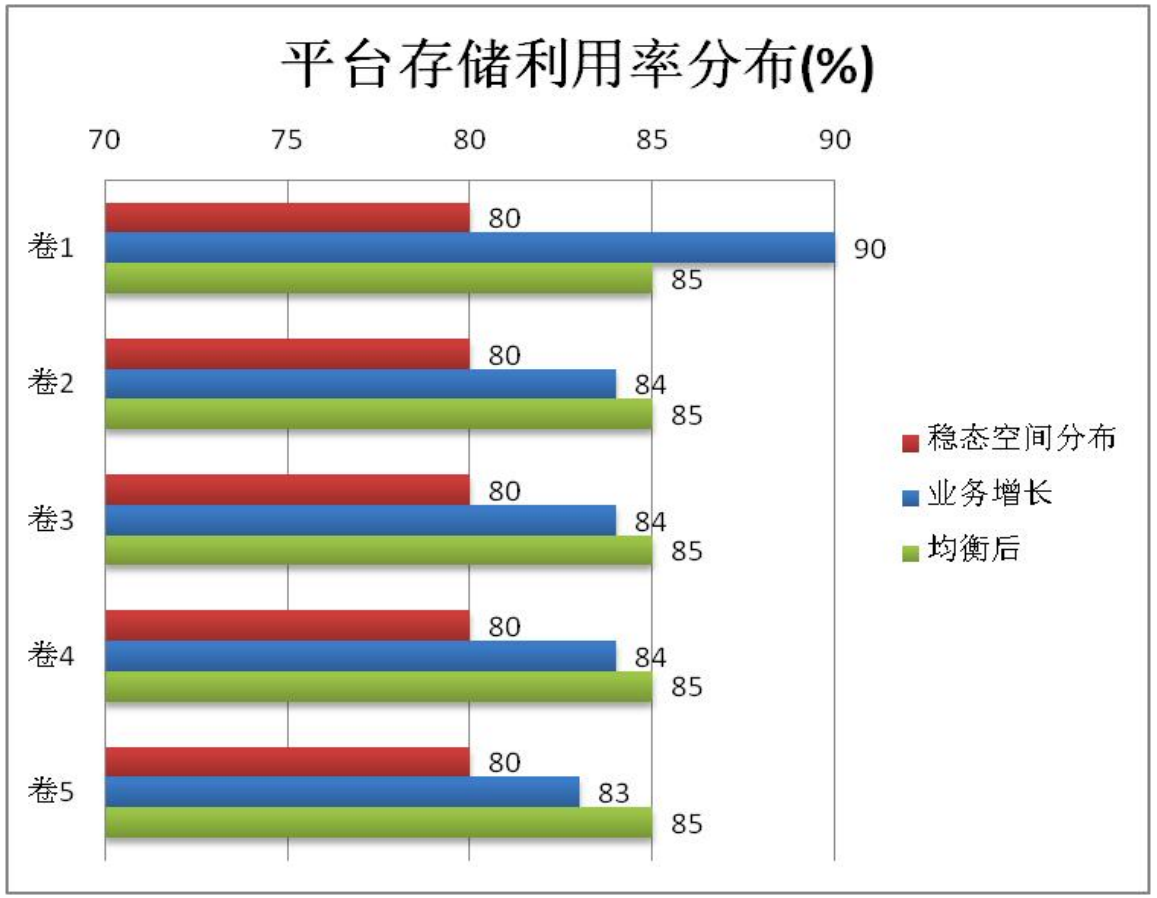
业务访问同比例




| | 卷1 | 卷2 | 卷3 | 卷4 | 卷5 |
|---|---|---|---|---|---|
| 大表A | 10 | 10 | 10 | 10 | 10 |
| 大表B | 20 | 20 | 20 | 20 | 20 |
| 大表C | 50 | 50 | 50 | 50 | 50 |

# 详细方案—平台动态调度(Schedule)

## 均衡——卷满均衡（优先级：高；自动发起）




- **场景：削峰！**
  业务增长
- **触发：**存在卷容量大于80%
  & 卷间利用率差大于2%
- **处理方法：**

  **选择源：**

  卷：利用率大于80%&大于平均水平的卷

  小表：在选中的卷中，根据大表的分布均衡情况选择

  **均衡顺序：**

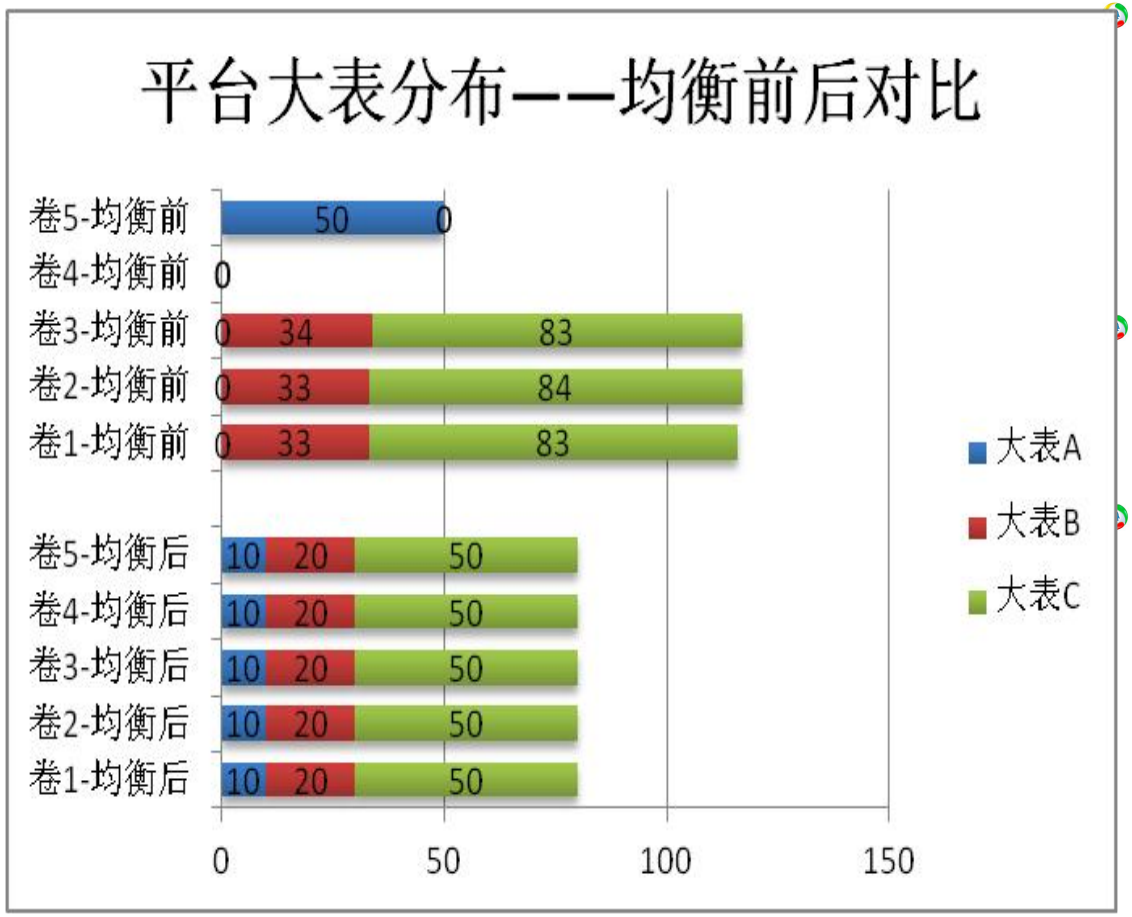
  优先处理容量占比最高的卷

  **选择目标：**（后续介绍）

腾讯网 QQ.com

# 详细方案—平台动态调度(Schedule)

## 均衡——大表均衡（优先级：低；自动发起）




**场景：大表分布不均**

资源变化：上架机器、上架业务、下架机器

业务增长导致不均（buffer充足）

**触发：卷容量、大表分布不均（差值大于10%）**

**处理方法：**

**选择源：**

卷：容量不均衡 || 大表不均的卷

小表：在选中的卷中，根据大表的分布均衡情况选择

**均衡顺序：**

优先处理容量占比最高的卷

**选择目标：**（后续介绍）

腾讯网 QQ.com

# 详细方案—平台动态调度(Schedule)

## 均衡算法

### 如何判断大表是否均衡：

理论值，大表在卷上的格子数：盘空间/平台总空间*100W

实际分布：根据路由计算卷上大表的格子总量

差值大于1个该业务小表的，认为不均衡：

理论值>实际分布： 可接受此大表的迁入

理论值<实际分布：需要均衡，优先迁出此大表的小表

### 源小表（适用于均衡）：

不均衡：选择大于均衡线大表

均衡：随机选择大表

在选中的大表中，选择range最大的小表

### 目标小表（适用于所有场景）：

满足下列条件的空闲资源最多的卷。

有足够资源（硬盘、内存）可以放这个小表

添加这个小表后，大表均衡分布

置换小表：

找出有足够资源、无法分配小表的卷

从中选择大表分布不均衡的小表B（存储量最小）

另外有空闲空间+小表，记为C，将C作为中转，B->C, A->B, C->A，置换A=B小表

腾讯网 QQ.com

# 详细方案—平台动态调度(Schedule)

## 分裂——小表分裂（优先级：高/中/低；自动发起）

- **场景：小表业务容量>=2GB**

  业务增长

- **触发：**小表容量>=2GB
- **处理方法：**

  **选择源：**

  小表：>=2GB的小表

  **顺序：**

  按照增长buf由多到排序；相同时，优先处理容量占比最高的卷

  **选择目标：**（参见均衡算法）

腾讯网 QQ.com

# 详细方案—平台动态调度(Schedule)

**迁移——dead小表迁移（优先级：高/中；自动发起）**

**场景：死机、坏盘剔除**

**触发：监控小表状态**

**处理方法：**

**选择源**：dead小表

**选择目标**：（参见均衡算法）

**限制**：迁移完成后，平台利用率低于95%才能启动。

- **迁移——不可用卷迁移（优先级：低；自动发起）**
- **场景：机器下架**
- **触发：监控小表状态**
- **处理方法：**

**选择源**：不可用卷上所有小表

**选择目标**：（参见均衡算法）

**限制**：证迁移完成后，平台利用率低于85%才能启动。

腾讯网 QQ.com

# 详细方案—平台动态调度(Schedule)

## 并发场景

现网常见场景的执行顺序：

高：卷满均衡

中： Dead小表（2份可用）

低：小表分裂 > 大表均衡

| \优先级<br>场景\ | 高 | 中 | 低 | 说明 |
| --- | --- | --- | --- | --- |
| 均衡-A | 卷满均衡 | | 大表均衡 | |
| 分裂-B | 2.7~3 | 2.4~2.7 | 2.1~2.4 | 已分配空间 |
| 迁移-C | Dead小表<br>1份可用 | Dead小表<br>2份可用 | 卷不可用 | |
| 手动-D | OSS插入 | OSS插入 | OSS插入 | |
| 同时出现 | C>A>B | C>B>A | B>C>A | |

腾讯网 QQ.com

# 详细方案—平台监控(OSS)

## 操作项——日常运维

上架资源

下架资源

限制：平台使用率低于85%时，才允许下架

步骤：在Master标识资源不可用，由Schdule调度迁移后，才能从master下架

上架大表

每个业务记录预分配资源，避免出现超卖

限制：需保证上架后有足够的空闲资源

下架大表

腾讯网 QQ.com

# 详细方案—平台监控(OSS)

## 操作项——自定义发起

**主要针对：**

调度失效后的，非常规处理手段

其他调度不覆盖的场景，如业务放量预处理

**操作分类：**

卷迁移

应对调度不及时场景：卷满

小表迁移：

Dead小表优先处理

分裂

应对业务放量 || 满小表提前分裂

大表均衡

针对机器访问量不均的场景

应对调度不及时场景：业务放量，上机器扩容

腾讯网 QQ.com

# 详细方案—平台监控(OSS)

## 监控项：

仓库监控：

场景1、监控仓库可用天数，预测需要扩容时间

场景2、监控仓库可用buffer用完（使用率90%），需要告警

卷监控：

场景1、展示卷的容量、均衡情况

场景2、 对于buffer充足，但是卷不均衡导致局部满的情况予以告警

小表监控：

展示死机小表，对于超时处理小表进行监控

展示满小表，预算可用天数，提供紧急告警

腾讯网 QQ.com

# 详细方案—平台动态调度(Schedule)

## 迁移评估

迁移模型：每个SET（30台TS8），配置两个并发迁移

迁移能力：1.74GB/分钟，可支持10%（3TB）/天的增长

| 时间评估 | *小表数据量（GB）* | 平均 *(>=200B)* | | | 最差情况 (全部小记录--40B) | | |
|---|---|---|---|---|---|---|---|
| | | 单小表 *(分钟)* | 总时间 *(小时)* | *迁移速率(GB/分钟)* | 单小表 *(分钟)* | 总时间 *(小时)* | *迁移速率(GB/分钟)* |
| 分裂整机 | *2.2/3* | 4 | 64 | *0.55* | 8 | 129 | *0.27* |
| 迁移整机 | *1.05/1.5* | 1.2 | 39 | *0.87* | 2.2 | 71 | *0.47* |
| 迁移10%小表 | *1.05/1.5* | 1.2 | 3.9 | *0.87* | 2.2 | 7 | *0.47* |

腾讯网 QQ.com

# 详细方案—平台动态调度(Schedule)

## 迁移评估

迁移模型：每个SET（30台TS8），配置两个并发迁移

迁移能力：1.74GB/分钟，可支持10%（3TB）/天的增长

| 时间评估 | *小表数据量（GB）* | 平均 *(>=200B)* | | | 最差情况 (全部小记录--40B) | | |
|---|---|---|---|---|---|---|---|
| | | 单小表 *(分钟)* | 总时间 *(小时)* | *迁移速率(GB/分钟)* | 单小表 *(分钟)* | 总时间 *(小时)* | *迁移速率(GB/分钟)* |
| 分裂整机 | *2.2/3* | 4 | 64 | *0.55* | 8 | 129 | *0.27* |
| 迁移整机 | *1.05/1.5* | 1.2 | 39 | *0.87* | 2.2 | 71 | *0.47* |
| 迁移10%小表 | *1.05/1.5* | 1.2 | 3.9 | *0.87* | 2.2 | 7 | *0.47* |

腾讯网 QQ.com

# 详细方案—性能分析

- 整组（3*TS8）性能数据

| value长度 | 测试稳态性能（IOPS） | | 对外性能（2/3） | |
|---|---|---|---|---|
| | GET | SET | GET | SET |
| 200B | 70000 | 14000 | 50000 | 14000 |
| 2KB | 60000 | 9500 | 40000 | 9000 |
| 4KB | 34000 | 10800 | 30000 | 10800 |
| 10KB | —— | —— | 12000 | 4320 |

- VS TSSDV3

| 平均记录大小 | ssd TIPS—get | ssd TIPS—set |
|---|---|---|
| 200B | 53000 | 16000 |
| 2KB | 40000 | 10000 |
| 4KB | 30000 | 13500 |
| 10KB | 12000 | 5500 |

腾讯网 QQ.com

# 业务升级计划

## 业务升级计划

FEED业务由于流量的问题，暂时延后升级

试割接业务——微信多媒体加速深圳/上海

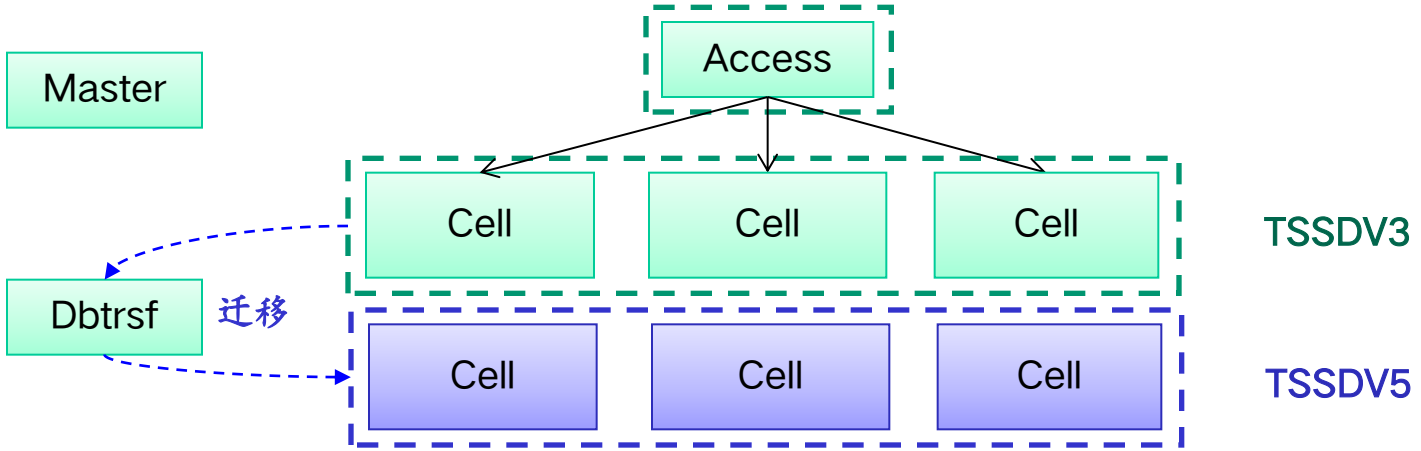
| 分类 | 仓库个数 | 总存储量GB | 现有设备(TS8) | 新系统设备数 | 节约设备数 |
|---|---|---|---|---|---|
| 多媒体 | 3 | 155827 | 465 | 315 | 150 |
| 其它应用 | 5 | 163211 | 480 | 336 | 144 |
| 图片索引 | 9 | 344468 | 1011 | 699 | 312 |
| 文件索引 | 3 | 39095 | 159 | 84 | 75 |
| FEED、说说 | 9 | 258549 | 1005 | 537 | 468 |
| 总计 | 29 | 961150 | 3120 | 1971 | 1149 |

腾讯网 QQ.com

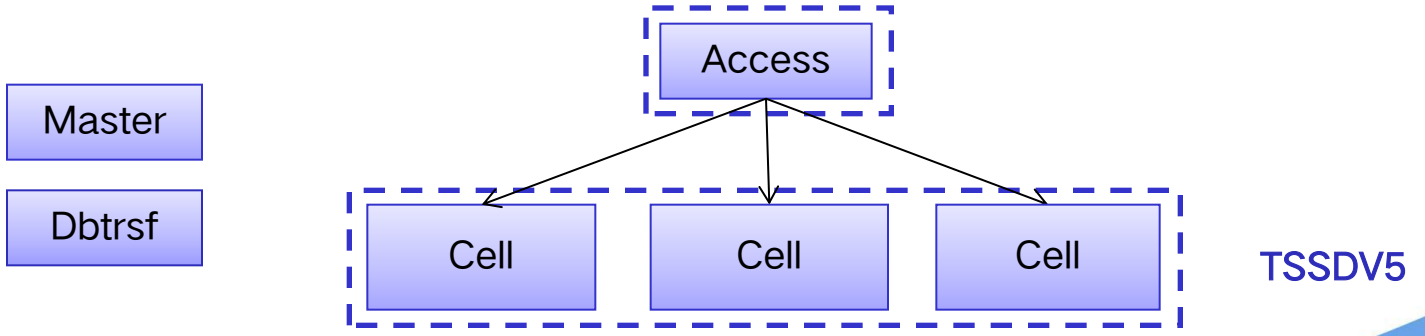
# 业务割接方案——仓库内升级

## 流程控制 – 业务割接流程

STEP1，迁移所有数据到TSSDV5_CELL上

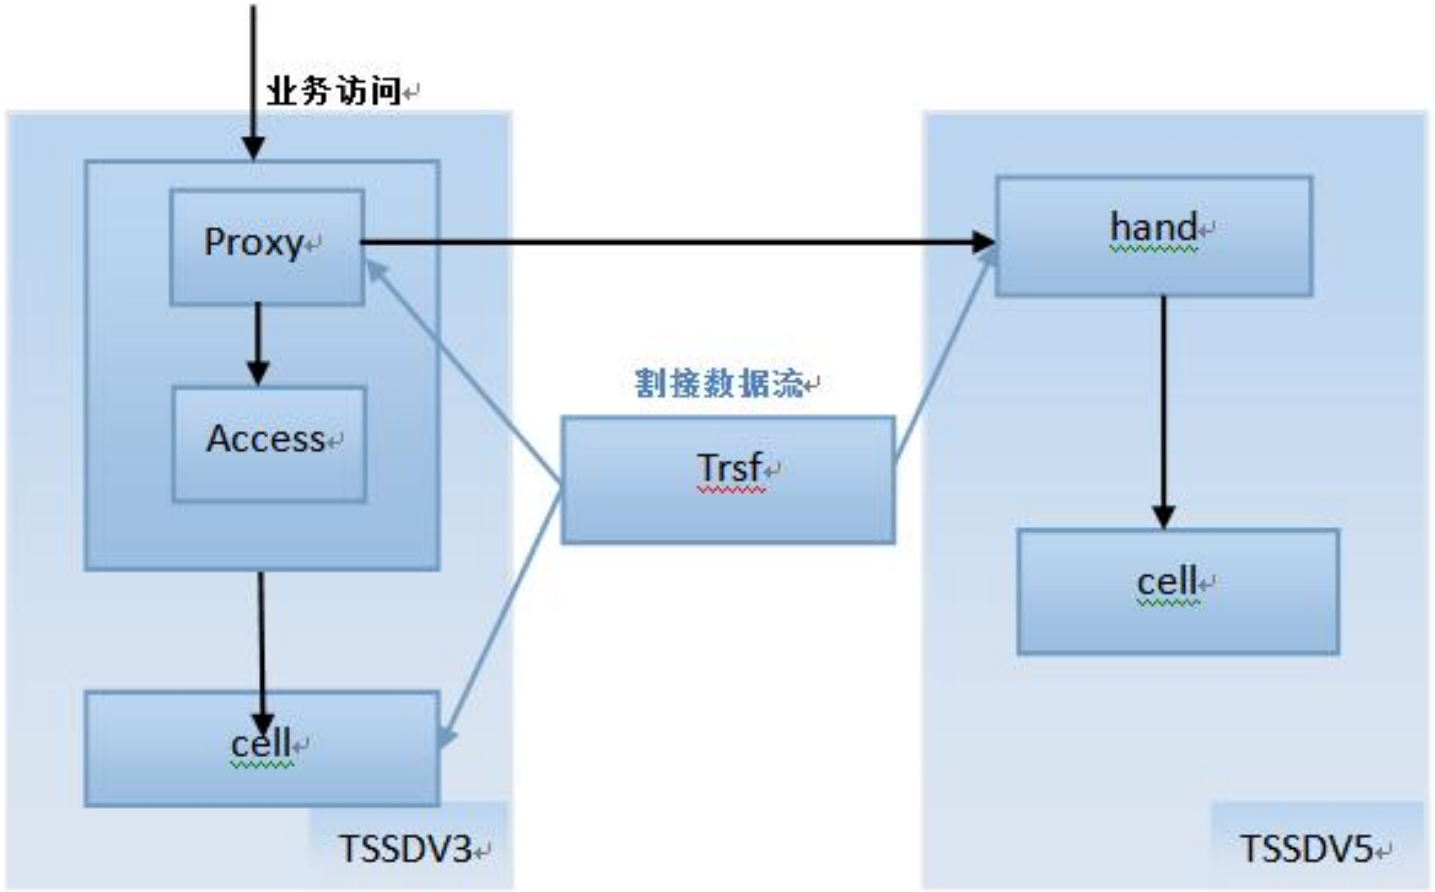



STEP2，变更access、master、dbtrsf版本，统一仓库版本为TSSDV5



# 业务割接方案——跨仓库割接

## 流程控制 – 业务割接流程



# 业务割接方案——跨仓库割接

## 割接评估

目标大表的创建——存储量以单小表1.05GB计算(仓库利用率60%)

割接速度：

小记录（150B：2小时）

大记录（2KB：7分钟）

小记录业务割接加速方案：

调整TSSDV5 CELL的写调度频率，从50ms->20ms

加大割接并发

上架TSSDV5大表时，容量给小一点

trsf add到V5过程中，相同桶的记录连续add,降低目标放大倍数——todo

腾讯网 QQ.com

# 实施计划

## 开发、测试阶段

3月　　核心系统方案细化

4月　　核心系统开发

5月　　测试

6月　　相关OSS开发、割接工具开发

## 灰度上线

7月　　灰度上线&效果验证

腾讯网 QQ.com

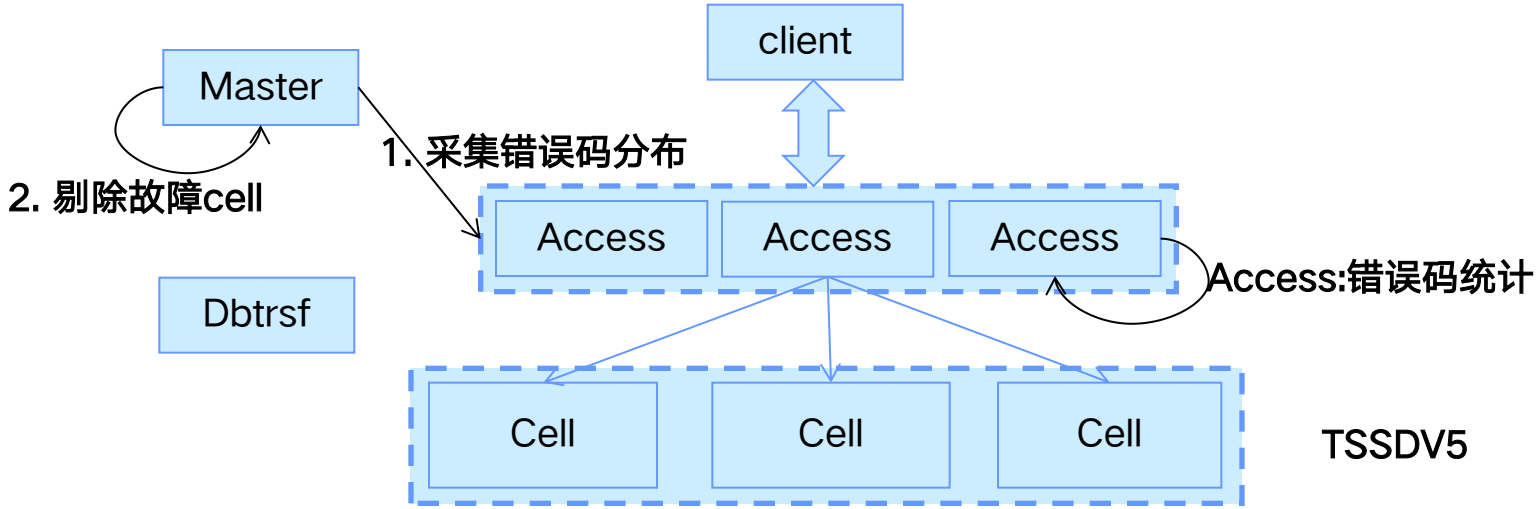
谢谢！

腾讯网 QQ.com

# 二期规划

## 可用性

错误码探测——master+access




毛刺收敛——cell：代码梳理，减少主流程内部流程耗时

腾讯网 QQ.com

# 二期规划—路由校验

## 背景：

结合现网运营经验和系统安全性考虑，V5核心系统期望加入访问路由检验，发现并拒绝路由错乱的访问，提高系统安全性。

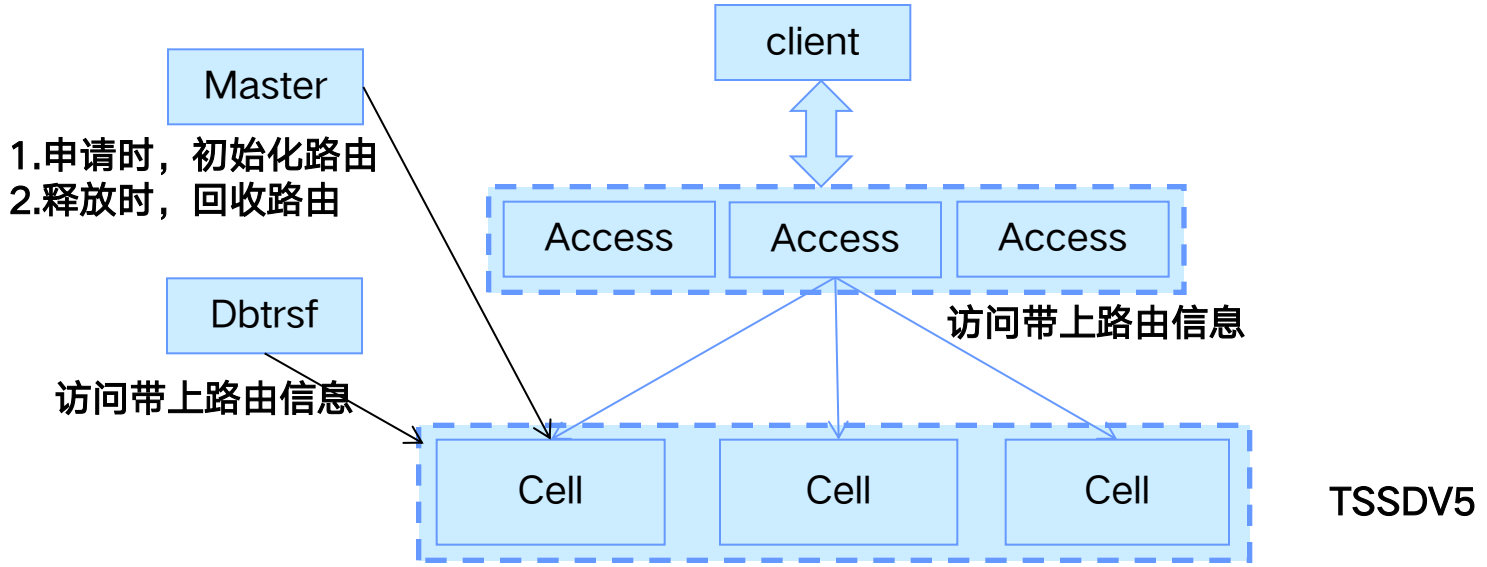
## 可以解决的场景：

1. access已下架，但业务仍然访问。后续路由变化未推送至下架access，导致数据访问错乱
2. access未清理已下架大表路由。如果旧业务持续访问，小表被新业务复用，将会影响新业务数据。
3. access和route进程路由数据不一致

腾讯网 QQ.com

# 二期规划—路由校验

## 方案结构图




CELL:

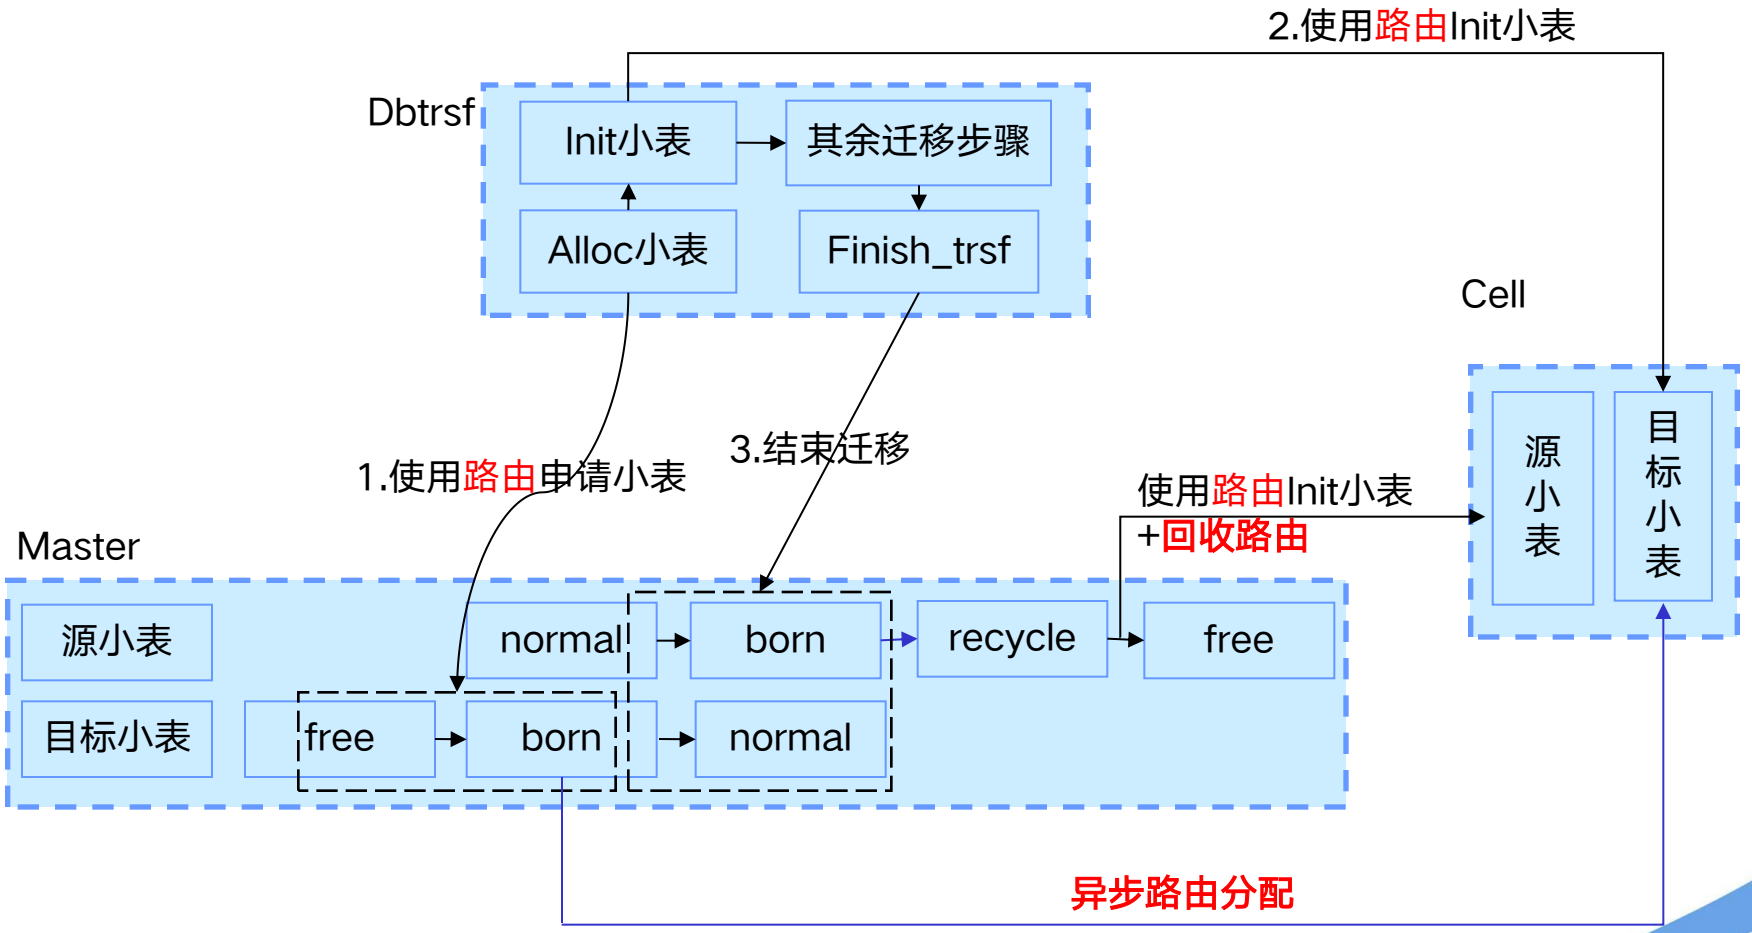
1.保存小表路由：tid , cid , range start , range end

2.校验请求路由，拒绝错乱

腾讯网 QQ.com

# 二期规划—路由校验

## 迁移小表路由变化



# 二期规划—路由校验

## 方案主要改动点：

| 模块 | 内容 |
| --- | --- |
| cell | 接口适配、路由落地 |
| master | 管理cell路由<br>1.回收小表时，分两步：清空路由; 释放数据，带路由参数;<br>2.分配小表后，异步初始化CELL中小表路由 |
| dbtrsf | 接口适配 |
| access | 接口适配、路由更新适配 |

腾讯网 QQ.com

# 二期规划—路由校验

**收益：**

规避access路由错乱导致的访问异常

**代价：**

master路由推送管理、小表状态管理支复杂化

master路由变化时需和cell的交互

**运营点：**

master路由推送情况管理

cell路由情况管理，接口添加较多

上架大表需流程改造，失败率可能变高

腾讯网 QQ.com

# 二期规划—路由校验

## 风险点梳理

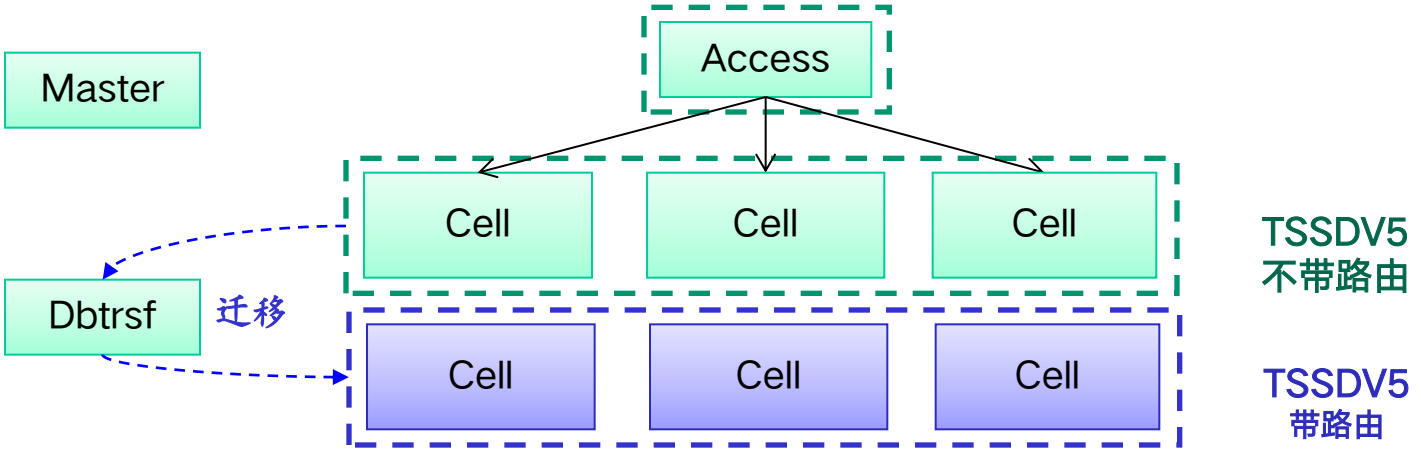
| 模块 | 影响 | 是否符合预期 | 后续处理方式 |
| --- | --- | --- | --- |
| master路由异常 | 路由异常范围小表访问拒绝 | 符合 | 人工介入恢复路由 |
| master推送cell失败 | 上架或迁移失败 | 符合 | 人工分析原因 |
| master回退 | 回退影响的小表访问全失败 | 符合 | 人工介入恢复路由 |
| Access路由异常 | 某台access全部失败 | 符合 | 人工介入<br>通知前端剔除access |
| cell路由异常 | 3分钟内到该台cell的访问失败 | 符合 | 仓库通过错误码剔除错误cell<br>人工分析原因 |

腾讯网 QQ.com

# 二期规划—路由校验

## 仓库内升级

1. 迁移所有数据到待路由校验CELL上，这时仓库内access仍然使用旧的访问接口，不会出现错误




2. 灰度变更access为路由临时版本
3. 变更master，外围工具推送路由到所有cell，并校验
4. 变更dbtrsf版本，发起迁移验证路由是否推送成功
5. 新上架一台带路由校验的access到仓库，从这台access访问，观察是否正常
6. 灰度变更现网access版本

腾讯网 QQ.com

# 二期规划—路由校验

## 工作排期

| 分类 | 模块 | 时间（天/单人） |
| --- | --- | --- |
| 设计 | Asn、各模块详细改动点 | 3 |
| 开发 | master | 6 |
| 开发 | cell | 3 |
| 开发 | access | 1 |
| 开发 | dbtrsf | 1 |
| 测试 | 单元测试 | 3 |
| 测试 | 联调测试 | 3 |
| 总计 | | 20 |

腾讯网 QQ.com

# 二期规划—冷备完整性加固

**冷备完整性加固：** 当前dump数据未关写，数据游离，dump不完整

Vs tssdv3，writecache更多，是否可直接关系？

按照block时间顺序进行dump?

# 二期规划

## 恢复速度——增量修复

迁移速度慢：一台机器故障迁移一天！根本原因：写速度慢 or 写数据量多

增量修复的方法：

操作流水——cell中时间点不可控

版本号——记录级别无足够内存

比对数据后，不一致记录的覆盖——数据量不可控，还需要进一步考虑

## FTL在TSSDV5的发展

存储层适配

FTL特性运营：如多份副本间局部数据修复（盘正常，数据损坏）

腾讯网 QQ.com

# OSS改动点梳理

| | | |
|---|---|---|
| 1. 上下架 | 机器上架 | a. 不同的安装包（master/access/cell/dbtrsf)<br>b. 添加schedule模块<br>c. 添加dbtrsf注册到master的功能 |
| | 机器下架 | a. cell机器下架需要置不可用<br>b. dbtrsf从master上解注册<br>c. schedule |
| | 大表上架 | a. 运维系统记录每个业务的占用容量<br>b. 业务上架需满足：所有业务的max(申请容量、当前容量)的和小于仓库的上限 |
| | 仓库监控 | a. 卷监控——不可用卷、卷容量、卷内大表不均衡情况<br>b. 大表容量监控——缩容、超过预分配量<br>c. 小表容量监控——分裂<br>d. 仓库满监控——上下架机器 |
| 2. 监控 | 状态监控 | a.dead小表<br>b.recycle小表<br>c.errorfree小表 |
| | 死机、坏盘 | a. master中错误码剔除的机器管理<br>b. 不需要迁移流程，只需检查是否小表状态<br>c. 恢复步骤中小表状态检查变成为free/recycle<br>d. tlinuxOS命令适配 |

腾讯网 QQ.com

# OSS改动点梳理

| | | |
|---|---|---|
| | 上架到仓库 | 触发场景：自然增长、故障、上架业务<br>条件：目标仓库使用率高、可用天数低等 |
| 3. 公共buffer池 | 从仓库中下架 | 触发场景：故障恢复、下架业务、缩容、业务数据量减少；<br>条件：利用率低、空闲小表数多+下架后可用时间够 |
| | 池的管理 | 资源不够业务增长以及故障buffer时，如何处理；<br>对所有池中的机器、仓库进行标签（机房、类型），根据标签匹配机器和仓库； |
| 4. 展示 | schedule管理 | 1. 在长任务中添加标签页展示<br>2. 从schedule中获取任务信息 |
| 5. 自定义入口 | schedule自定义任务发起 | 迁移、分裂、缩容任务发起 |

腾讯网 QQ.com